

1er Parcial de Introducción al Aprendizaje Automático

Primer cuatrimestre de 2025

Responder cada ejercicio en hoja aparte e incluir en todas las hojas:

Nombre:

e-mail:

Los siguientes ejercicios emplean el conjunto de datos Iris disponible desde la biblioteca Scikit-learn. El conjunto de datos de flores Iris se hizo famoso por Ronald Fisher e incluye medidas del ancho y largo de los pétalos y sépalos para distintas especies de flores del género Iris.

Ejercicio 1) Explorar el conjunto de datos a través de las salidas del método `info()`

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 6 columns):
#   Column          Non-Null Count  Dtype  
---  --
0   sepal length (cm) 150 non-null   float64
1   sepal width (cm)  150 non-null   float64
2   petal length (cm) 150 non-null   float64
3   petal width (cm)  150 non-null   float64
4   target            150 non-null   int64   
5   species           150 non-null   object  
dtypes: float64(4), int64(1), object(1)
memory usage: 7.2+ KB
```

y del método `describe()`

	sepal length (cm)	sepal width (cm)	petal length (cm)	petal width (cm)
count	150.000000	150.000000	150.000000	150.000000
mean	5.843333	3.057333	3.758000	1.199333
std	0.828066	0.435866	1.765298	0.762238
min	4.300000	2.000000	1.000000	0.100000
25%	5.100000	2.800000	1.600000	0.300000
50%	5.800000	3.000000	4.350000	1.300000
75%	6.400000	3.300000	5.100000	1.800000
max	7.900000	4.400000	6.900000	2.500000

1.a) ¿Cuántos registros contiene el conjunto de datos? ¿Cuáles son las variables y qué tipo de información almacenan?

El conjunto de datos cuenta con 150 instancias o muestras (filas) y 6 campos (columnas). Las variables 'sepal length (cm)', 'sepal width (cm)', 'petal length (cm)', 'petal width (cm)' son variables numéricas del tipo de punto flotante. La variable 'target' es una variable numérica

entera aunque almacena información de las distintas clases. Finalmente, la variable 'species' es un objeto con información del tipo categórica.

1.b) ¿En cuáles campos se observan faltantes de datos, no válidos o nulos?

No se observan faltantes de datos o nulos ya que todas las variables contienen valores para los 150 registros.

1.c) ¿Se puede considerar el valor máximo de la serie de 'sepal length (cm)' como *outlier*? Análogamente, ¿se puede considerar su mínimo como *outlier*? ¿Por qué?

Opción 1:

El valor máximo (7.9) de 'sepal length (cm)' no representa un outlier ya que se ubica dentro del intervalo dado por el criterio de 3 sigmas alrededor de la media ($5.843 \pm 3 \cdot 0.828$). Esto es,

$$5.843 + 3 \cdot 0.828 = 8.327$$

$$5.843 - 3 \cdot 0.828 = 3.359$$

Análogamente, se puede ver que el mínimo (4.3) también se encuentra comprendido entre los extremos del mismo intervalo.

Opción 2:

El valor máximo (7.9) de 'sepal length (cm)' no representa un outlier ya que se ubica por debajo del valor máximo obtenido con el criterio del rango inter-cuartílico. Esto es,

$$Q3 + 1.5 \text{ IQR} = 6.4 + 1.5 \cdot (6.4 - 5.1) = 8.35$$

Análogamente, se puede ver que el mínimo (4.3) también se encuentra por encima del valor mínimo obtenido con el criterio del rango inter-cuartílico. Esto es,

$$Q1 - 1.5 \text{ IQR} = 5.1 - 1.5 \cdot (6.4 - 5.1) = 3.15$$

1.d) Obtener la cantidad de instancias para la especie setosa conociendo parcialmente la salida del método `value_counts()`. ¿Es una muestra balanceada?

```
species
setosa      ?
versicolor  50
virginica   50
Name: count, dtype: int64
```

Sabiendo que el conjunto de datos consta de 150 instancias, sin datos nulos, entonces existen 50 muestras de la clase setosa. Así, es un conjunto perfectamente balanceado ya que existen igual número de muestras para cada clase.

1.e) La columna 'species' no forma parte del conjunto de datos original. Se agregó para facilitar la interpretación del 'target':


```
target → species
0 → setosa
1 → versicolor
2 → virginica
```

¿Podríamos implementar un modelo de regresión para la variable 'target' que emplee todos los atributos numéricos y que, además, incluya las especies como variables dummies codificadas en columnas del tipo one-hot?

Por un lado, no corresponde aplicar un modelo de regresión lineal para la variable 'target' ya que representa clases de flores (aunque estén codificadas por números enteros). Se podría considerar regresiones logísticas aunque deberían ser 3 (o 2), una por cada especie. Pero lo más importante es que no se puede tomar la variable 'species' como atributo ya que se refiere directamente al 'target'. Esto sería un leak de información. Esto no lo cambia su representación por variables del tipo one-hot.

Ejercicio 2) Se desea construir un árbol de decisión solo utilizando el atributo 'sepal length (cm)'. Para esta parte, se propone evaluar dos posibles puntos de corte iniciales para este atributo. Las siguientes tablas resumen cómo se distribuyen las clases del dataset Iris según los dos posibles cortes iniciales

Opción 1: sepal length (SL) < 5.45			Opción 2: sepal length (SL) < 6.15		
Clase	SL < 5.45	SL ≥ 5.45	Clase	SL < 6.15	SL ≥ 6.15
Setosa	48	2	Setosa	50	0
Versicolor	3	47	Versicolor	40	10
Virginica	0	50	Virginica	8	42



Recordamos que para un conjunto con 3 clases ($k=3$), la probabilidad de que las muestras pertenezcan a la clase i en un dado nodo es p_i , y la impureza de Gini se calcula como:

$$I_G = 1 - \sum_{i=1}^k p_i^2$$

Finalmente, si el conjunto de datos D se particiona en 2 subconjuntos D_1 , D_2 la impureza de Gini ponderada es

$Gini(D) = \frac{n_1}{n} I_G(D_1) + \frac{n_2}{n} I_G(D_2)$ donde $n = n_1 + n_2$ son los tamaños de los subconjuntos D_1 y D_2 , respectivamente.

2.a) Para cada opción, calculá el Gini total ponderado. Compará los valores de Gini total ¿Cuál tiene menor impureza total? ¿Qué significa eso sobre la calidad?

Opción 1: sepal length < 5.45

$$I_G(D1) = 1 - p_{c1}^2 - p_{c2}^2 - p_{c3}^2 \quad I_G(D2) = 1 - p_{c1}^2 - p_{c2}^2 - p_{c3}^2$$

$$\text{Impureza ponderada: } Gini(\text{Opción 1}) = \frac{n_1}{n} I_G(D1) + \frac{n_2}{n} I_G(D2)$$

- **SL < 5.45** (n = 51): Setosa = 48, Versicolor = 3, Virginica = 0

$$I_G(D1) = 1 - \left(\frac{48}{51}\right)^2 - \left(\frac{3}{51}\right)^2 - \left(\frac{0}{51}\right)^2 = 1 - 0.887 - 0.004 - 0 = 0.110$$

- **SL ≥ 5.45** (n = 99): Setosa = 2, Versicolor = 47, Virginica = 50

$$I_G(D2) = 1 - \left(\frac{2}{99}\right)^2 - \left(\frac{47}{99}\right)^2 - \left(\frac{50}{99}\right)^2 = 1 - 0.0004 - 0.225 - 0.225 = 0.520$$

$$\text{Gini total: } Gini(\text{Opción 1}) = \frac{51}{150} 0.110 + \frac{99}{150} 0.520 = 0.380$$

Podían usar 2 decimales, pero ojo como redondearon!

Opción 2: sepal length < 6.15

- **SL < 6.15** (n = 98): Setosa = 50, Versicolor = 40, Virginica = 8

$$I_G(D1) = 1 - \left(\frac{50}{98}\right)^2 - \left(\frac{40}{98}\right)^2 - \left(\frac{8}{98}\right)^2 = 1 - 0.260 - 0.167 - 0.007 = 0.566$$


- **SL ≥ 6.15** (n = 52): Setosa = 0, Versicolor = 10, Virginica = 42

$$I_G(D2) = 1 - \left(\frac{0}{52}\right)^2 - \left(\frac{10}{52}\right)^2 - \left(\frac{42}{52}\right)^2 = 1 - 0 - 0.037 - 0.653 = 0.310$$


$$\text{Gini total: } Gini(\text{Opción 1}) = \frac{98}{150} 0.566 + \frac{52}{150} 0.310 = 0.477$$

La opción 1 tiene menor Gini total (0.3806 vs 0.4772).

2.b) Usando la mejor opción, armá un diagrama simple del árbol de decisión que muestre el criterio del nodo raíz e indica cuántos ejemplos caen a cada lado.




A partir del árbol anterior, se realizó un árbol incorporando el atributo 'petal length (cm)'. El diagrama del mismo se muestra a continuación.



2.c) ¿Cuál es la profundidad del árbol? Sobre el gráfico de los atributos que se muestra a continuación graficar la frontera de decisión que corresponde al diagrama de este nuevo árbol.

La profundidad del árbol es 2.



2.d) Obtener la matriz de confusión, la exactitud (accuracy), exhaustividad (recall) y precisión para la clase virginica en la tabla de la opción 2..

		Predicted condition	
Total population = P + N		Positive (PP)	Negative (PN)
Actual condition	Positive (P)	True positive (TP)	False negative (FN)
	Negative (N)	False positive (FP)	True negative (TN)

Sources: [4][5][6][7][8][9][10]

42 (TP)	8 (FN)
10 (FP)	90 (TN)

$$\text{acc} = (42 + 90) / (42 + 90 + 10 + 8) = 0.88$$



$$\text{recall} = 42 / (42 + 8) = 0.84$$

$$\text{precision} = 42 / (42 + 10) = 0.808$$

Ejercicio 3) Se quiere generar un modelo de regresión lineal para la predicción del largo del pétalo ('petal length (cm)') de un conjunto de sépalos de flores de un museo. A partir del dataset Iris, se escogió trabajar con las variables 'sepal length (cm)' y 'sepal width (cm)'.



3.a) Observe los parámetros obtenidos del modelo y los gráficos de las variables individuales vs el target. Explique el significado de los coeficientes β_1 y β_2 e interprete:

$$\text{Petal length (cm)} = -2.63 - 1.28 * \text{Sepal width (cm)} + 1.77 * \text{Sepal length (cm)}$$



3.a) β_1 y β_2 nos indican la variación de la predicción respecto de las dos variables "Sepal width (cm)" y "Sepal length (cm)". $\beta_1 = -1.28$ nos indica que por cada centímetro que crece "Sepal width (cm)", decrece el target "Petal length (cm)" por 1.28 cm (No están escaleados). Lo opuesto sucede con "Sepal length (cm)".

Sin embargo, al observar los gráficos se ve que las tendencias son similares, por lo que β_1 y β_2 deberían tener el mismo signo "+". El modelo, al no ver la distinción entre especies, obtiene un valor negativo para β_1 , perdiendo la relación natural entre las variables.



3.b) Dada la siguiente muestra del conjunto de **evaluación**, calcule la predicción de cada una de las instancias y el RMSE de la muestra.

	Sepal width (cm)	Sepal length (cm)	Petal length (cm)
1	2.8	6.1	4.7
2	3.8	5.7	1.7
3	2.6	7.7	6.9
4	2.9	6.0	4.5
5	2.8	6.8	4.8

$$RMSE = \sqrt{\frac{1}{N} \sum (y - y_{pred})^2}$$

$$(4.70 - 4.59)^2 = 0.01$$

$$(1.70 - 2.61)^2 = 0.83$$

$$(6.90 - 7.68)^2 = 0.61$$

$$(4.50 - 4.29)^2 = 0.04$$

$$(4.80 - 5.83)^2 = 1.06$$

$$RMSE: 0.71$$

3.c) Se introduce ahora la variable especie ('species') en formato de variables dummies de la siguiente manera.

```
iris['setosa'] = np.where(iris['species'] == 'setosa', 1, 0)
iris['versicolor'] = np.where(iris['species'] == 'versicolor', 1, 0)
```



```

X = iris[['sepal width (cm)', 'sepal length (cm)', 'setosa',
'versicolor']]
y = iris['petal length (cm)']

np.random.seed(42)
X_train, X_test, y_train, y_test = train_test_split(X, y,
train_size=0.7)

reg = LinearRegression()
reg.fit(X_train, y_train)

```

3.c.i) Observe nuevamente los coeficientes β_1 y β_2 y compare con los del punto 3.a).


3.c.ii) Interprete los coeficientes de las variables Dummies D1 y D2.

3.c.iii) ¿Por qué no se incluyó la especie virginica?

$$Petal\ length = + 1.18 - 0.1 * Sepal\ width + 0.62 * Sepal\ length - 3.13 * D1 - 0.88 * D2$$

3.c.i) Luego de introducir las variables dummies, se observa una reducción significativa en ambos coeficientes ($\beta_1^{(2)} \approx \beta_1/10$ y $\beta_2^{(2)} \approx \beta_2/3$), por lo que la variación del target dado una variación en las variables “Sepal width (cm)” y “Sepal length (cm)” es menor que en el caso anterior.

(El signo de $\beta_1^{(2)}$ en realidad es “+”, typo, se observa cómo al introducir las variables dummy el modelo adopta la relación natural de las variables)



3.c.ii) Las variables dummies D1 y D2 funcionan como “interruptores” para encender y apagar sus pesos (β_3 y β_4). Una instancia de la clase “setosa”, hará que se active β_3 y se desactive β_4 , bajando el valor de la predicción en 3.13 cm. Idem para “versicolor”.

3.c.iii) Incluir la especie “virginica” es redundante, ya que cuando una instancia sea de esta especie, D1 y D2 serán nulas, por lo que queda definida la opción restante “virginica” en la cuál no disminuye la predicción a iguales valores de “sepal width” y “sepal length”. (Notar que, en promedio, “virginica” es la especie con pétalos más largos).


3.d) El RMSE del segundo modelo para la misma muestra que el punto 3.b es igual a 0.369. Concluya sobre la elección de un modelo basado en el conjunto evaluado y la métrica de performance.

Si únicamente cuento con esas instancias, dado que el error es considerablemente menor en el segundo modelo, se elegiría este. Sin embargo, solo se evaluó con una MUESTRA y no con todo el conjunto, por lo que una mejor decisión se debería basar en la evaluación sobre todo el conjunto de test.

Ejercicio 4) Utilizando el mismo conjunto de datos, se entrenó un modelo para diferenciar entre las especies ‘versicolor’ y ‘virginica’, en base a las variables ‘petal width (cm)’ y ‘sepal width (cm)’. El modelo utilizado es una regresión logística.

$$P(y = 1|x_1, x_2) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2)}}, \text{ con } x_1 = \text{petal width y } x_2 = \text{sepal width.}$$

Luego de entrenar el modelo se obtuvieron los valores $(\beta_0, \beta_1, \beta_2) = (6.6, -4.3, 0.2)$



4.a) ¿Cómo se define la frontera de decisión para el modelo de regresión logística?

La frontera de decisión está constituida por aquellos puntos tales que

$$P(y = 1|x_1, x_2) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2)}} = 0.5.$$

4.b) Obtenga la ecuación de la frontera de decisión para este modelo. Grafique aproximadamente en la figura.

Despejando:

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 = 0 \rightarrow x_2 = -\beta_0/\beta_2 - \beta_1/\beta_2 x_1 = -33 + 21.5x_1$$

También pueden despejar al revés

$$x_1 = -\beta_0/\beta_1 - \beta_2/\beta_1 x_2 = 1.53 + 0.05x_2$$


Punto bonus si entendieron que el umbral se puede dejar como variable.

Reemplazando valores (puede ser en cualquiera de las dos variables, es más fácil reemplazando x_2 ya que la pendiente es grande (vs x_1))


$$x_1(x_2 = 2) = 1.53 + 0.05(2) = 1.63$$

$$x_1(x_2 = 3) = 1.53 + 0.05(3) = 1.68$$

Como la frontera es una recta ya alcanza para graficar



4.c) Para la frontera dibujada, calcule el TPR (True Positive Rate) y el FPR (False Positive Rate). Considere a la clase 'versicolor' como la clase positiva.




Tenemos 50 de cada clase. Los cuatro círculos rojos son falsos positivos, el círculo verde es falso negativo

$$TPR = TP / P = TP / (TP + FN) = 49/50 = 0.98$$

$$FPR = FP / N = FP / (FP + TN) = 4/50 = 0.08$$

4.d) Dibuje aproximadamente la curva ROC para este modelo. ¿Cómo se obtienen los diferentes puntos de esta curva? ¿Tienen distintas fronteras de decisión?




Aprox. (0, 0) es clasificador todo clase negativa (umbral muy alto → nada es clase positiva). (1, 1) es clasificador todo clase positiva (umbral muy bajo → todo es positivo). Cada punto

es para un umbral distinto. Cada umbral representa una frontera de decisión distinta (cambia la ordenada, no la pendiente, por lo que la recta se desplaza)

4.e) Suponga que un investigador viaja al campo a recolectar especímenes de 'versicolor', y que va a utilizar nuestro modelo para reconocerlas rápidamente en el campo. Luego de recolectarlas va a realizar un análisis (bastante caro) para detectar una mutación genética. Teniendo en cuenta que el presupuesto es acotado, ¿qué umbral le recomendaría?

Si el presupuesto está acotado tiene más sentido minimizar los falsos positivos antes que maximizar el TPR. El umbral de 0.5 es razonable ($FPR = 0.08$). Aumentar un poco el umbral ayudaría a reducir el FPR (somos más estrictos para clasificar algo como positivo, la frontera de decisión se mueve hacia la izquierda), lo que equivaldría a elegir en la curva ROC algún punto entre el (0, 0) y el (0.08, 0.98), sin llegar al (0, 0) que equivaldría a no recolectar ninguna muestra.

Ejercicio 5) Se realiza una regresión por vecinos más cercanos para la variable dependiente 'petal length (cm)' tomando los atributos 'sepal length (cm)', 'sepal width (cm)' y 'species'. La siguiente figura representa el RMSE y el coeficiente de determinación en función de la inversa de la cantidad de vecinos más cercanos



5.a) Asignar a las curvas 1 y 2 los conjuntos de datos de prueba y de entrenamiento, si corresponden.

La curva 1 representa la respuesta del conjunto de entrenamiento. La curva 2 lo hace para el conjunto de prueba. La elección se puede apoyar en observar errores más altos sobre todos (o casi) los puntos de la curva que representa a los datos de prueba y el aspecto "U" visto frecuentemente en los datos de prueba.

5.b) ¿Qué cantidad de vecinos deberían emplearse para un desempeño balanceado del modelo? En ese caso, ¿cuál es el error esperado en las predicciones?

El desempeño del modelo tiende al menor error para k entre 3 a 6 vecinos. En ese rango el error (irreducible) rondaría 0.3cm para la predicción del 'petal length (cm)'.

5.c) Si se tomaran más de 10 vecinos, ¿cuál es el efecto que considera domina sobre el error del modelo?

Para más de 10 vecinos, el modelo se torna más rígido, predominan los errores de sesgo y se observa un underfitting en los conjuntos de entrenamiento y prueba.

5.d) Si se tomaran 1 o 2 vecinos, ¿cuál es el efecto que considera domina sobre el error del modelo?

Para 1 o 2 vecinos más cercanos, el modelo es muy flexible, predomina los errores por varianza y se observa un overfitting en el conjunto de datos de entrenamiento. Es decir, el modelo lleva al extremo la reducción de diferencias entre valores predecidos y observados del conjunto de prueba. Finalmente, el modelo termina ajustando el error asociado a los puntos de entrenamiento, empeorando la predicción sobre los puntos de prueba y ampliando la distancia entre las curvas 1 y 2.

5.e) Hallar el valor de la variable 'Petal length (cm)' que el modelo predeciría en función del número de vecinos (k). Asumimos que todos los puntos tienen igual peso (*weights='uniform'*). ¿Por qué podemos afirmar que el punto que elegimos para predecir el valor de 'Petal length (cm)' coincide con un punto de entrenamiento?

k	sepal length (cm)	sepal width (cm)	species	distancia	petal length (cm)	Pred
1	6.1	3.0	versicolor	0.000	4.6	
2	6.1	2.9	versicolor	0.223	4.7	
3	5.9	3.0	versicolor	0.241	4.2	
4	6.0	2.9	versicolor	0.254	4.5	

k=1, 'petal length (cm)' = 4.6

k=2, 'petal length (cm)' = $(4.6 + 4.7) / 2 = 4.65$

k=3, 'petal length (cm)' = $(4.6 + 4.7 + 4.2) / 3 = 4.5$

k=4, 'petal length (cm)' = $(4.6 + 4.7 + 4.2 + 4.5) / 4 = 4.5$

Los vecinos más cercanos se buscan del conjunto de entrenamiento. El punto que elegimos para predecir 'petal length (cm)' se encuentra a distancia cero (0.00) del primer vecino (k=1). Por tanto, coincide con un punto de entrenamiento.