

Ejercicio 1 (1 punto)

El conjunto de datos utilizado en este parcial contiene información clínica de chicos y adolescentes que podrían padecer apendicitis. El objetivo es analizar y modelar los datos para predecir la presencia de apendicitis en los pacientes, aplicando técnicas de análisis exploratorio de datos y aprendizaje automático. En principio vamos a trabajar el conjunto de datos con solo 10 atributos y el target (*Diagnosis*).



```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 782 entries, 0 to 781
Data columns (total 11 columns):
 #   Column              Non-Null Count  Dtype  
---  --
 0   Edad                781 non-null   float64
 1   Masa Corporal       755 non-null   float64
 2   Diametro apendice   498 non-null   float64
 3   Visibilidad apendice 777 non-null   object  
 4   Gas en intestino    140 non-null   object  
 5   Fluidos libres      719 non-null   object  
 6   Conteo de Glóbulos Blancos 776 non-null   float64
 7   Pedida de hambre    772 non-null   object  
 8   Inflamacion         252 non-null   object  
 9   Coprostasis        71 non-null    object  
10  Diagnostico         780 non-null   object  
dtypes: float64(4), object(7)
memory usage: 67.3+ KB
```


- (0.25) ¿Cuáles columnas son numéricas y cuáles categóricas?
- (0.25) ¿Cuántas columnas tienen valores faltantes en el conjunto de datos de apendicitis pediátrica?
- (0.50) El conjunto de datos de apendicitis pediátrica incluye el atributo "Visibilidad del apéndice", que es categórica y puede tener valores como "Visible", "No Visible" o "Parcialmente Visible". ¿Qué técnica de preprocesado se podría utilizar para trabajar con este atributo? Justificar.

Ejercicio 2 (2 puntos)

A la izquierda se muestra un boxplot del Conteo de Glóbulos blancos por Diagnóstico y a la derecha se muestra un Heatmap de Correlaciones de las variables numéricas.




- a. (0.5) Observando el Boxplot, ¿qué significan los puntos fuera de los "bigotes" del boxplot? Explicar brevemente con qué técnica de preprocesamiento de datos vista en clase se relaciona.
- b. (0.5) ¿Qué muestra el Heatmap? Interprete las correlaciones entre Edad y Masa Corporal, y entre Conteo de Glóbulos Blancos y Diámetro apéndice. De forma más general, explique, brevemente, qué significan los valores cercanos a 1, cercanos a -1, y cercanos a 0 en una correlación.
- c. (0.5) Se realizó un gráfico de las variables Conteo de glóbulos blancos vs Diámetro del apéndice separados por el Diagnóstico. Marcar con Verdadero o Falso los siguientes enunciados. Luego, elige uno de los tres enunciados y justifica tu respuesta:
 - i. Las dos clases no son completamente separables en los atributos seleccionados, ya que existe un error irreducible.
 - ii. Es posible obtener una muy buena separación de ambas clases observando el atributo 'Conteo de glóbulos blancos'
 - iii. Es posible obtener una muy buena separación de ambas clases observando el atributo 'Diámetro del apéndice'




- d. (0.5) Si quisieras predecir la probabilidad de que un paciente pediátrico tenga apendicitis, ¿qué modelo utilizarías y por qué?

Ejercicio 3 (1 punto)

A continuación se esquematiza un árbol de decisión utilizado para clasificar el diagnóstico de apendicitis, asignando la clase 1 al diagnóstico positivo y clase 0 al diagnóstico negativo.



- a. Calcule las 2 impurezas Gini faltantes ($Gini = 1 - \sum_{Clases(C)} (S_c/S)^2$). Interprete.
- b. Dibuje en el siguiente gráfico la frontera de decisión correspondiente al árbol anterior.




Ejercicio 4 (1 punto)

Posteriormente, se realizó una clasificación del diagnóstico utilizando una Regresión Logística. Después de entrenar el modelo, se obtuvo la siguiente regresión logística:


$$p(y = 1 | x_1, x_2) = \frac{1}{1 + e^{-(w_0 + w_1 x_1 + w_2 x_2)}} \quad \text{cuyos parámetros son:}$$

$$w_0 = 106, \quad w_1 = -2.2, \quad w_2 = -2.$$

- a. Obtenga y dibuje la frontera de decisión y asigne la clase correspondiente a cada región. ¿Cuál es la ordenada al origen y pendiente de esa frontera?



- b. El siguiente gráfico muestra un gráfico de la regresión logística para un caso de clasificación binaria con un único atributo. El eje x muestra el conteo de glóbulos blancos y el eje y muestra la probabilidad de la clase positiva. Considerando un umbral de 0.5, dibuje la frontera de decisión y dé un valor aproximado de la misma.



Ejercicio 5 (1 punto)

Considerando los modelos Árbol de Decisión, Random Forest, Regresión Logística, Regresión Lineal y k-vecinos más cercanos, asigne a qué modelo corresponde el enunciado (puede asignar más de un enunciado a cada modelo y viceversa).

- En general, modelo base para modelos más complejos de Ensamble.
- Ideal para problemas de clasificación binaria, separando las clases con fronteras lineales. Además, puede proporcionar probabilidades de clase por construcción.
- Robusto frente al sobreajuste porque promedia los resultados de múltiples modelos para obtener una predicción final más precisa y estable.
- Pueden ser naturalmente usados tanto para regresión como para clasificación.
- No hace ninguna suposición sobre la distribución de los datos y se basa en la distancia entre puntos para realizar predicciones.
- Maneja bien los valores atípicos y puede manejar fácilmente grandes conjuntos de datos.
- Este modelo es altamente interpretable y permite visualizar las decisiones en un gráfico, lo que facilita la explicación a personas no técnicas
- Es computacionalmente intensivo durante la fase de predicción, ya que requiere calcular distancias entre el punto de prueba y todos los puntos de entrenamiento.
- Las reglas de decisión de este algoritmo pueden ser muy susceptibles a pequeños cambios en el conjunto de datos.
- Puede llevar a predicciones incorrectas si los datos no son escalados adecuadamente

Ejercicio 6 (2 puntos)

Utilizando un Random Forest se obtuvo la siguiente matriz de confusión:

MC	Predicción: Apendicitis	Predicción: No Apendicitis
Apendicitis	392	88
No Apendicitis	55	255

- Calcular la exactitud (*accuracy*), exhaustividad (*recall*) y precisión del modelo.
- En un contexto como el conjunto de datos de apendicitis, ¿por qué es importante la métrica de exhaustividad (*recall*) en lugar de simplemente usar la exactitud (*accuracy*) para evaluar el modelo?
- Para el mismo conjunto de datos, escribir la matriz de confusión de un clasificador que predice siempre la clase positiva. ¿Cuál es su exactitud, exhaustividad y precisión?
- Dibuje una curva ROC aproximada para este modelo Random Forest. Marque los puntos que correspondan al clasificador evaluado en la matriz MC y en la del inciso c.

Ejercicio 7 (1 punto)

Utilizando el conjunto de datos de apendicitis, ahora queremos predecir la variable 'Tiempo de hospitalización' [días] (variable continua) utilizando una regresión lineal.

- (0.30) Suponga que tiene ahora los siguientes datos de entrenamiento. $X = [-3, 5, 4]$ e $Y = [-10, 20, 20]$. Se ha entrenado un modelo simple de regresión lineal y se han obtenido las siguientes predicciones del modelo para los valores de X : $Y_{pred} = [-9, 21, 19]$. Calcule el Error Cuadrático Medio (*MSE*, *Mean Squared Error*).
- (0.70) A continuación, se presenta el resultado de evaluar por medio de validación cruzada (*cross-validation*) en 5 particiones (*folds*) al modelo de regresión lineal. La métrica de evaluación seleccionada es el Error Cuadrático Medio (*MSE*), obteniendo los siguientes resultados para cada partición

Fold	1	2	3	4	5
Entrenamiento	2.9	2.5	1.9	2.4	2.0
Validación	4.5	3.8	4.2	4.0	4.1

- ¿Cuál es el valor promedio del MSE obtenido para cada conjunto? ¿Qué interpretación puedes darle a este resultado?
- ¿Qué ventajas tiene el uso de validación cruzada respecto a utilizar un solo conjunto de evaluación (*train-test split*)? Explique brevemente. Por ejemplo, considere el caso donde queremos comparar el desempeño de dos modelos.

Ejercicio 8 (1 punto)

Tanto evaluando el problema de clasificación como de regresión se estudiaron diversos métodos para controlar el overfitting.

- a. Se listan a continuación diversos clasificadores y acciones que pueden afectar el sesgo y la varianza. Indique cómo el sesgo y la varianza cambian en respuesta a la acción. Marcar la opción correcta.

i) Reducir el hiperparámetro profundidad en un Árbol de Decisión:

Sesgo	Varianza
Disminuye	Disminuye
Aumenta	Aumenta
No cambia	No cambia

ii) Aumentar el hiperparámetro k en un clasificador KNN:

Sesgo	Varianza
Disminuye	Disminuye
Aumenta	Aumenta
No cambia	No cambia

- b. El siguiente gráfico muestra las curvas de error de entrenamiento y testeo para la regresión a medida de que se agregan atributos a la misma (aumenta la complejidad del modelo). Indique sobre el gráfico:

- Cual de las curvas mostradas es el error del entrenamiento y cual el error del testeo.
- Hacia qué lado del gráfico aumenta y disminuye el sesgo.
- Hacia qué lado del gráfico aumenta y disminuye la varianza.
- Donde la regresión pareciera mostrar un overfitting y donde un underfitting

