

Recuperatorio de Introducción al Aprendizaje Automático

Segundo cuatrimestre de 2024

Nombre:

e-mail:

Los siguientes ejercicios emplean datos descargados desde la plataforma de datos abiertos del Banco Mundial. El conjunto de datos corresponde a indicadores de desarrollo por países estimados en años recientes. Las series de datos representan:


Código	Descripción	Unidades
Country Name	Nombre del país	
Year	Año	
Exportaciones	Exportaciones	(% del PIB)
Agro_Pesca	Valor agregado por la agricultura y la pesca	(% del PIB)
PIB_PC	Producto interno bruto (PIB) per cápita	(dólares)
Gasto_Educ_Estado	Gasto del Estado en educación	(% del PIB)
Gasto_Salud	Gastos en salud	(% del PIB)
Gasto_Salud_Estado	Gasto del Estado en salud	(% del PIB)

Ejercicio 2) Se suma un nuevo atributo ('Cat_Ingreso') que agrupa los registros por países de bajos y altos ingresos:


```
mean_gdppp = wdi_regions['PIB_PC'].mean()
wdi_regions.loc[:, 'Cat_Ingreso'] = np.where(wdi_regions['PIB_PC'] > mean_gdppp, 1, 0)
wdi_regions['Cat_Ingreso'].value_counts()
```

Cat_Ingreso	#Registros
0	1548
1	622
Name: count,	dtype: int64

De esta forma, 'Cat_Ingreso'=1 señala los países con ingresos superiores a la media y 'Cat_Ingreso'=0 señala los países con ingresos inferiores a la media. Considerando esta partición, el histograma de 'Agro_Pesca' (el impacto de la agricultura sobre el PIB) muestra la siguiente distribución por tipo de ingreso:



Distribución de 'Agro_Pesca' por ingresos



Árbol obtenido con SciKit-Learn

2.a) Elaborar un árbol de decisión similar al presentado en la figura superior asumiendo que el criterio de decisión es 'Agro_Pesca' < 5. Completar el nodo raíz y las hojas con los valores de impureza de Gini, número de muestras, valores, y clase asignada. 'Cat_Ingreso_TH5' es el nombre que daremos al campo que guarda las instancias clasificadas según el nuevo criterio de decisión. El resultado de las 4 posibles combinaciones es:

Cat_Ingreso	Cat_Ingreso_TH5	# Registros
0	0	1235
0	1	313
1	0	119
1	1	503


Recordamos que para un conjunto con 2 clases, la probabilidad de que las muestras pertenezcan a la clase i en un dado nodo es p_i , y la impureza de Gini se calcula como

$$I_G = 1 - \sum_{i=1}^2 p_i^2$$

Finalmente, si el conjunto de datos D se particiona en 2 subconjuntos D_1 , D_2 la impureza de Gini pesada es

$$Gini(D) = \frac{n_1}{n} I_G(D_1) + \frac{n_2}{n} I_G(D_2)$$

donde $n = n_1 + n_2$ son los tamaños de los subconjuntos D_1 y D_2 , respectivamente.



$$IG = 1 - (313/816)^2 - (503/816)^2$$

$$IG = 1 - 0.147 - 0.380$$

$$IG = 0.473$$

$$IG = 1 - (1235/1354)^2 - (119/1354)^2$$

$$IG = 1 - 0.832 - 0.008$$

$$IG = 0.160$$

2.b) Obtener la reducción de la función de impureza de acuerdo al nuevo criterio (es decir, con el umbral de 5 previamente mencionado). ¿Por qué SciKit-Learn asigna, aproximadamente, 2.5 al umbral que separa entre ambas clases? ¿Cuál es el impacto (reducción) en la función de impureza en este segundo caso?

Umbral: 5

$$\text{Gini} = (816/2170) * 0.473 + (1354/2170) * 0.16$$

$$\text{Gini} = 0.178 + 0.100 = 0.278$$

$$\text{Reducción} = 0.278 - 0.409 = -0.131$$

Umbral: 2.5


$$\text{Gini} = (540/2170) * 0.283 + (1630/2170) * 0.191$$

$$\text{Gini} = 0.070 + 0.143 = 0.213$$

$$\text{Reducción} = 0.213 - 0.409 = -0.196$$

SciKit-Learn toma el umbral de 2.5 porque es el que más reduce la impureza de Gini.

2.c) Obtener la matriz de confusión, la exactitud (accuracy), exhaustividad (recall) y precisión del modelo cuyo umbral de clasificación es 5.



$$\text{Accuracy} = (tp + tn) / (tp + tn + fp + fn)$$

$$\text{Accuracy} = (1235 + 503) / (1235 + 503 + 313 + 119) = 0.801$$


$$\text{Recall} = tp / (tp + fn)$$

$$\text{Recall} = 503 / (503 + 119) = 0.809$$

$$\text{Precision} = tp / (tp + fp)$$

$$\text{Precision} = 503 / (503 + 313) = 0.616$$

2.d) Recuperar la matriz de confusión para el umbral 2.5 a partir de la figura para su árbol de decisiones. Calcular la exactitud, la exhaustividad y la precisión.



$$\text{Accuracy} = (tp + tn) / (tp + tn + fp + fn)$$

$$\text{Accuracy} = (1456 + 448) / (1456 + 448 + 92 + 174) = 0.877$$

$$\text{Recall} = tp / (tp + fn)$$

$$\text{Recall} = 448 / (448 + 174) = 0.72$$


$$\text{Precision} = tp / (tp + fp)$$

$$\text{Precision} = 448 / (448 + 92) = 0.83$$

2.e) Interpretar el impacto de variar el umbral de clasificación de 2.5 a 5. ¿Qué métrica(s) mejora(n) cuando la función de impureza desciende más marcadamente?

Accuracy mejora para mayor reducción de la impureza de Gini (la tasa de error es más baja cuando las clases son más puras). Análogamente para la precisión.

Ejercicio 3) Presentamos las correlaciones entre algunas series de datos. Incluimos también el nuevo atributo 'Cat_Ingreso' construido según el extracto anterior. Asimismo, agregamos otro atributo, 'LatAm', que clasifica a los países según si pertenecen o no pertenecen a la región de América Latina y el Caribe:



3.a) El atributo 'Cat_Ingreso' tiene una muy alta correlación con el ingreso per cápita ('PIB_PC'). ¿Es conveniente incluirlo en una regresión lineal para predecir 'PIB_PC'? (Recordar cómo se construyó este indicador.)

El atributo 'Cat_Ingreso' sería un leak para la regresión. (Se construyó usando el target: 'PIB_PC')

3.b) ¿Cómo se interpretan las correlaciones ligeramente negativas para el atributo 'LatAm' que identifica países pertenecientes a América Latina y el Caribe con los restantes atributos?

Los países que pertenecen a la región de América Latina y el Caribe tienden a tener menores exportaciones y menor PIB per cápita respecto a los que no pertenecen a la región.

3.c) Si se practica una regresión lineal para estimar el ingreso per cápita usando un sólo atributo por vez ('Exportaciones', 'Gasto_Salud_Estado', 'Gasto_Salud', 'Cat_Ingreso', 'LatAm'), ¿Cómo se ordenarían los resultados según el RMSE? Comenzar por el atributo con el cual se obtendría el RMSE más bajo. Justificar este ordenamiento.

Teniendo en cuenta las correlaciones más altas con el target 'PIB_PC' el ordenamiento es:

1ro 'Gasto_Salud_Estado', 2do 'Exportaciones', 3ro 'Gasto_Salud', 4to 'LatAm'
(Recordar que 'Cat_Ingreso no se usa por ser un leak)

3.d) Si ahora se practica una regresión lineal para estimar el ingreso per cápita usando dos atributos, ¿cuáles elegiría y por qué?

Nuevamente, teniendo en cuenta las correlaciones más altas con el target 'PIB_PC' los atributos son:

'Gasto_Salud_Estado' y 'Exportaciones',

3.e) Si ahora se practica una regresión lineal para estimar el ingreso per cápita usando tres atributos, ¿cuáles elegiría y por qué?

Nuevamente, teniendo en cuenta las correlaciones más altas con el target 'PIB_PC' y reconociendo que 'Gasto_Salud_Estado' y 'Gasto_Salud' están fuertemente correlacionados, los atributos son:

'Gasto_Salud_Estado', 'Exportaciones', y 'LatAm'

Ejercicio 4) Realizamos una regresión lineal para ajustar el ingreso per cápita ('PIB_PC') tomando los siguientes atributos: 'Exportaciones', 'Gasto_Salud_Estado', 'LatAm'. Luego del ajuste, se obtienen los siguientes valores para sus respectivos parámetros:

```
array([ 290.80583131, 3966.73426449, -5126.30010382])
```

4.a) ¿Es 'LatAm' una variable categórica? ¿Cuáles son sus clases? ¿Cómo se ha convertido para poder incorporarse a la regresión lineal?

'LatAm' es una variable categórica o booleana. Las clases pueden ser *pertenece* o *no_pertenece* si se almacenan como cadena de caracteres. En el caso booleano serán True o False.

'LatAm' es una variable dummy en la regresión lineal en la que cada una de sus clases se codifican como 0 o 1. No importa la asignación para realizar la regresión pero sí se debe tener presente en la interpretación de los resultados.

4.b) ¿Cómo podría sostenerse que un país de Latinoamérica tiene un ingreso per cápita inferior a otros del resto del mundo con similares niveles de exportaciones y gastos en salud? ¿Es compatible con la correlación observada con la variable dependiente 'PIB_PC'? Aproximadamente, ¿en qué medida es inferior el ingreso en la región?

Observando el parámetro (coeficiente) que multiplica al atributo 'LatAm'. Su valor es, aproximadamente, -5100 luego de ajustar los coeficientes. Así, si se asigna 1 a los países que pertenecen a la región, vemos que la predicción se reduce en 5100 dólares. Y es compatible con la correlación negativa observada entre 'LatAm' y 'PIB_PC'.

4.c) Si las exportaciones de un país aumentan un 1%, ¿cuánto se espera que crezca el ingreso per cápita manteniendo constantes los atributos restantes?

Luego de ajustar los coeficientes vemos que el parámetro que multiplica al atributo exportaciones es, aproximadamente, 290 dólares/porcentaje. Según sus unidades expresadas en % respecto del PIB, un aumento en 1 punto en las exportaciones llevaría a un crecimiento de 290 dólares.

4.d) Se evalúa el desempeño del modelo mediante validación cruzada. Los resultados del coeficiente de determinación R^2 son:

`array([0.48288724, 0.50536953, 0.45806068, 0.33855402, 0.48169542])`

Obtener un valor representativo del grado de acuerdo y de su incertidumbre. ¿Qué operaciones se han realizado para obtener dichos valores?

El promedio resulta igual a 0.453

La desviación estándar es 0.067


4.e) ¿Cuál sería el coeficiente de determinación R^2 que se obtendría con un modelo benchmark (banco de pruebas) que siempre predice el valor medio de 'PIB_PC'? ¿Resulta el modelo propuesto superador respecto al benchmark? Recordamos que el coeficiente de determinación se define como

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

donde la suma al cuadrado de los residuos es $SS_{res} = \sum_i (\hat{y}_i - y_i)^2 = \sum_i \epsilon_i^2$, la suma al cuadrado total (proporcional a la varianza de los datos) es $SS_{tot} = \sum_i (y_i - \bar{y})^2$, y_i es el valor observado (target), $\hat{y}_i$ es la predicción, $\bar{y}$ es el valor medio de las observaciones.

Ya que el modelo benchmark predice la media, entonces $\hat{y}_i = \bar{y}$. Por tanto SS_{res} y SS_{tot} son iguales y $R^2 = 1 - 1 = 0$

Ejercicio 5) Se realiza una regresión por vecinos más cercanos para la variable dependiente ingreso per cápita ('PIB_PC') tomando los mismos atributos que en el ejercicio anterior: 'Exportaciones', 'Gasto_Salud_Estado', 'LatAm'. La siguiente figura representa el RMSE en función de la inversa de la cantidad de vecinos más cercanos empleados para estimar el ingreso.



5.a) Asignar a las curvas 1 y 2 los conjuntos de datos de prueba y de entrenamiento, si corresponden.

La curva 1 representa los datos de entrenamiento, la 2 corresponde a los datos de prueba.

5.b) ¿Qué cantidad de vecinos deberían emplearse para optimizar el desempeño del modelo? En ese caso, ¿cuál es el error esperado en las predicciones?

En cercanías de 5 vecinos podemos observar el desempeño óptimo. La curva de datos de prueba evidenciaría un mínimo en el entorno de 0.2 y el error esperado sería cercano a 10.000 dólares. Más aún, este valor es similar al alcanzado con los datos de entrenamiento.


5.c) Si se tomaran más de 10 vecinos, ¿cuál es el efecto que considera domina sobre el error del modelo?

El modelo tiende a subajustar (underfitting) cuando el número de vecinos más cercanos es mayor a 10. El efecto que domina es el sesgo. Se confirma porque dando más flexibilidad al modelo (menos vecinos) ambas curvas, entrenamiento y prueba, muestran un descenso en el error.


5.d) Si se tomaran 1 o 2 vecinos, ¿cuál es el efecto que considera domina sobre el error del modelo?

El modelo tiende a sobreajustar (overfitting) cuando el número de vecinos más cercanos es de 1 o 2. El efecto que domina es la varianza y se confirma por la separación observada entre las curvas de entrenamiento y prueba. La distancia a los datos de entrenamiento es mínima lo que conduce a una reducción notable del error en entrenamiento. Sin embargo, al ajustar los datos de prueba con los mismos parámetros el acuerdo es mucho menor resaltando el efecto de sobreajuste.

Ejercicio 6) (solamente para los que recuperan) Buscamos clasificar nuevamente a los países según su ingreso considerando los atributos 'Gasto_Educ_Estado' (Gasto del Estado en educación como % del PIB) y 'Gasto_Salud_Estado' (Gasto del Estado en salud como % del PIB). Planteamos dos modelos de regresión logística: i) empleando regularización de Lasso, ii) empleando regularización de Ridge. Las siguientes figuras muestran las fronteras de decisión para diferentes valores del hiperparámetro 'C' (inversa de la intensidad de la regularización) obtenidas con SciKit-Learn:



Modelo Lasso



Modelo Ridge

Asimismo, obtenemos los siguientes valores para los parámetros beta: i) β_1 corresponde a 'Gasto_Educ_Estado' y ii) β_2 corresponde a 'Gasto_Salud_Estado'.

Modelo	C	β_0	β_1	β_2	$ \beta_1, \beta_2 $
Lasso	10	-1.61	-1.00	2.19	
Lasso	1	-1.59	-0.97	2.16	
Lasso	0.1	-1.44	-0.75	1.90	
Lasso	0.01	-0.76	0.00	0.82	
Lasso	0.001	0.00	0.00	0.00	
Ridge	10	-1.60	-1.00	2.19	
Ridge	1	-1.58	-0.96	2.14	
Ridge	0.1	-1.38	-0.72	1.81	
Ridge	0.01	-0.84	-0.20	0.95	
Ridge	0.001	-0.23	0.01	0.24	

6.a) ¿Por dónde pasa la frontera de decisión para un modelo de regresión logística sin regularización? ¿Cambia su ubicación según si se traza sobre la figura correspondiente al modelo Lasso o sobre la figura correspondiente al modelo Ridge?

La frontera de decisiones de un modelo sin regularizar prácticamente coincidiría con las fronteras señaladas para el hiperparámetro $C=10$. En efecto, como el cambio en los parámetros beta es mínimo entre $C=1$ y $C=10$, podemos inferir que sin regularización (equivalente a C muy grande) los resultados serían similares a los vistos para $C=10$.

Ciertamente, la frontera de decisiones de un modelo sin regularizar se ubicaría en la misma posición en ambas gráficas ya que no depende de un esquema de regularización particular. Vemos que el modelo Lasso y el Ridge muestran los mismos valores de los parámetros beta para C grande. Es de esperar ya que, en ambos casos, C grande tiende al modelo sin regularización.

6.b) ¿Por qué el modelo Lasso muestra una frontera horizontal para valores del hiperparámetro cercanos a 0.01?

Lo que se observa es que cuando el hiperparámetro C alcanza un valor cercano a 0.01, se anula uno de los valores de beta, 'Gasto_Educ_Estado'. Es una reducción de atributos que habilita el modelo. Implica que las predicciones ya no dependen de 'Gasto_Educ_Estado' y por lo tanto cualquiera sea su valor el resultado es el mismo. Esto se traduce como una frontera de decisiones horizontal (solo depende del valor de 'Gasto_Salud_Estado').

6.c) ¿Por qué no se observa una frontera en el modelo Lasso cuando el hiperparámetro vale 0.001? ¿Cuál será la probabilidad que está asignado el modelo a los distintos atributos?

Para valores de C cercanos a 0.001, la reducción de atributos es tan fuerte que el modelo ya no depende de ellos (beta es estrictamente cero). La probabilidad de asignar una clase es independiente de los atributos

$$P(x) = P = 1 / (1 + \exp(0)) = 1 / (1 + 1) = 0.5$$


El argumento de la exponencial es nulo ya que el ajuste del modelo de Lasso fijó en 0 a todos los betas. Finalmente, para todo punto la probabilidad es la misma. Según se fije el umbral por encima o por debajo de 0.5, todos los puntos pertenecerán a la clase de Altos o Bajos Ingresos, respectivamente.

6.d) Completar la tabla con el cálculo del módulo de los vectores de parámetros $||\beta_1, \beta_2||$ con la norma L_1 o L_2 , según corresponda al modelo considerado.

Lasso, L_1 , [3.19, 3.13, 2.65, 0.82, 0.0]

Ridge, L2, [2.40, 2.34, 1.94, 0.97, 0.24]

6.e) Representar la variación de los parámetros β_1 y β_2 en función de la norma calculada anteriormente para los modelos Lasso y Ridge (pueden emplearse dos gráficos separados). Interpretar los resultados.



Se destaca como el modelo Lasso fija el β_1 en 0 para valores menores a 0.8, aprox. Esto lo interpretamos como una reducción de atributos. Sin embargo, en el modelo de Ridge observamos que ambos betas se reducen cuando C es más chico (mayor fuerza de regularización) aunque nunca llegan a cero.

6.f) Los modelos regularizados requieren que los atributos se normalicen previamente. ¿Dependen los valores hallados para los nuevos parámetros β de los valores medios y desviaciones calculados para realizar el cambio de escala? ¿Por qué?

Ciertamente, los valores de β dependen de la escala usada en los atributos. Valores grandes de atributos conducen a betas pequeños, y viceversa. La regularización de Lasso y la de Ridge tratan de minimizar el tamaño (módulo) del vector β . Si los atributos no estuvieran escalados, entonces obtendríamos regularizaciones diferentes de acuerdo a las unidades elegidas para los atributos. Para evitar este problema, se transforman primero los atributos. Finalmente, los resultados dependen de los valores medios y desviaciones calculados para efectuar las transformaciones de escala.