
Introducción al Aprendizaje Automático


1er cuatrimestre 2025



Universidad
Nacional
de San Martín

¿Qué es el Aprendizaje Automático?


Software Tradicional



**Inferencia /
predicción**

Desarrollo

Aprendizaje Automático



Resumiendo: en Aprendizaje Automático, las “reglas” se aprenden automáticamente (valga la redundancia). No tenemos que programarlas.

Aprendizaje Automático

¿Y cómo aprendemos esas “reglas”? A partir de datos.

Un programa de computación se dice que aprende de una experiencia E con respecto a una tarea T y una métrica de performance P , si la performance sobre T , medida por P , mejora con la experiencia E .

- Tom Mitchell, 1997

Es decir, un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.

- Tarea
- Medida de desempeño
- Experiencia



Un poco de formalismo

Solemos contar con un conjunto de datos, compuesto de diferentes mediciones - características - sobre cierto número de *instancias*. En general, buscaremos predecir una de esas características, que será el target o *output* y .

- Si y es continua, es un problema de regresión.
- Si y es categórica, es un problema de clasificación.

El conjunto de características que utilizaremos para predecir y lo solemos notar $\mathbf{X}$.

- $\mathbf{X}$: atributos (features) o *inputs* .

En general, son más de uno. Cada atributo es una columna, y cada instancia una fila, por lo que $\mathbf{X}$ suele ser una matriz.

Un poco de formalismo

Solemos contar con un conjunto de datos, compuesto de diferentes mediciones - características - sobre cierto número de *instancias*. En general, buscaremos predecir una de esas características, que será el target o *output* y .

- Si y es continua, es un problema de regresión.
- Si y es categórica, es un problema de clasificación.

El conjunto de características que utilizaremos para predecir y lo solemos notar **X** .

- **X** : atributos (features) o *inputs* .

En general, son más de uno. Cada atributo es una columna, y cada instancia una fila, por lo que **X** suele ser una matriz.

species	island	culmen_length_mm	culmen_depth_mm	flipper_length_mm	body_mass_g	sex
Chinstrap	Dream	50.2	18.7	198.0	3775.0	FEMALE
Adelie	Torgersen	37.8	17.1	186.0	3300.0	NaN
Adelie	Dream	39.5	17.8	188.0	3300.0	FEMALE
Gentoo	Biscoe	47.4	14.6	212.0	4725.0	FEMALE
Gentoo	Biscoe	50.8	17.3	228.0	5600.0	MALE

Un poco de formalismo

- **X**: atributos (features) o *inputs* .
- **y**: target, etiquetas, *output*.

Asumimos que existe una relación entre ellos de la forma

$$y = f(x) + \varepsilon$$

f es una función desconocida - la que queremos **estimar** -, mientras que ε es el *error*.

- La aproximación que haremos de f - nuestro modelo - se suele notar $\hat{f}(X)$.
- Existen muchísimas estrategias para aproximar f , cada una dando como resultados distintos modelos.

Un poco de formalismo

- **X**: atributos (features) o *inputs*.
- **y**: target, etiquetas, *output*.

Asumimos que existe una relación entre ellos de la forma

$$y = f(x) + \varepsilon$$

f es una función desconocida - la que queremos **estimar** -, mientras que ε es el *error*.

- La aproximación que haremos de f - nuestro modelo - se suele notar $\hat{f}(X)$.
- Existen muchísimas estrategias para aproximar f , cada una dando como resultados distintos modelos.

$$\text{species} = f(\text{island } \text{culmen_length_mm } \text{culmen_depth_mm } \text{flipper_length_mm } \text{body_mass_g } \text{sex}) + \varepsilon$$

Un poco de formalismo

- **X**: atributos (features) o *inputs* .
- **y**: target, etiquetas, *output*.

Asumimos que existe una relación entre ellos de la forma

$$y = f(x) + \varepsilon$$

f es una función desconocida - la que queremos **estimar** -, mientras que ε es el *error*.

- La aproximación que haremos de f - nuestro modelo - se suele notar $\hat{f}(X)$.
- Existen muchísimas estrategias para aproximar f , cada una dando como resultados distintos modelos.

¿Para qué queremos obtener un modelo?

Inferencia y predicción

Predicción

Atributos (**X**, *inputs*) fácilmente conseguibles, pero no así las etiquetas (*y*, *outputs*)
→ Usamos el modelo para obtener *y*.

Ejemplo.

- **X**: variables medidas en un análisis de sangre
- *y*: embarazo o no

Inferencia

Nos interesa entender la relación entre **X** e *y*, no necesariamente para hacer predicciones.

¿Cuáles predictores - elementos de **X** - están asociados con *y*? ¿Cuál es esa relación? ¿Es lineal?
¿Es más compleja?

Ejemplo.

- **X**: variables medidas en un análisis de sangre y otros estudios clínicos.
- *y*: diagnóstico de una enfermedad rara.

¿Qué podemos hacer para diferenciarlos?




[IAA_Clase_2_Demo.ipynb](#)

Aprendizaje Supervisado

- Clasificación


Aprendizaje Supervisado

¿Cuántos atributos? ¿Cuántas columnas tendría un dataframe?





Aprendizaje Supervisado



¿Cuántos atributos? ¿Cuántas columnas tendría un dataframe?




Aprendizaje Supervisado




Aprendizaje Supervisado



Aprendizaje Supervisado - Frontera de decisión




Aprendizaje Supervisado - Frontera de decisión



Este proceso, así de sencillo, ya devuelve un modelo.

En clasificación, un modelo está caracterizado por una frontera de decisión.

Aprendizaje Supervisado - Frontera de decisión



Este proceso, así de sencillo, ya devuelve un modelo.

En clasificación, un modelo está caracterizado por una frontera de decisión.

Para pensar:

¿Qué pasa si usamos el atributo 2 en lugar del uno? ¿Cómo es la nueva frontera de decisión?

¿Cómo sería con los dos a la vez?

Árboles de Decisión

- Los árboles de decisión son un tipo de modelo de aprendizaje automático que se utiliza para clasificar y predecir resultados basados en características de entrada.
- Se basan en la lógica de decisiones, donde se evalúan las características de entrada y se toman decisiones basadas en reglas predefinidas.
- Los árboles de decisión se utilizan en una amplia variedad de aplicaciones, como clasificación de texto, diagnóstico médico, análisis de riesgo y recomendación de productos.
- Los árboles de decisión se pueden construir de manera manual o automática, utilizando algoritmos de aprendizaje automático.
- Los árboles de decisión son fáciles de interpretar y explicar, lo que los hace útiles para aplicaciones donde la transparencia es importante.
- Los árboles de decisión pueden ser entrenados con datos etiquetados y se utilizan para predecir el resultado de nuevas instancias de datos.
- Los árboles de decisión pueden ser optimizados para mejorar su rendimiento, utilizando técnicas como poda y selección de características.
- Los árboles de decisión son un tipo de modelo de aprendizaje automático que se utiliza para clasificar y predecir resultados basados en características de entrada.
- Se basan en la lógica de decisiones, donde se evalúan las características de entrada y se toman decisiones basadas en reglas predefinidas.
- Los árboles de decisión se utilizan en una amplia variedad de aplicaciones, como clasificación de texto, diagnóstico médico, análisis de riesgo y recomendación de productos.
- Los árboles de decisión se pueden construir de manera manual o automática, utilizando algoritmos de aprendizaje automático.
- Los árboles de decisión son fáciles de interpretar y explicar, lo que los hace útiles para aplicaciones donde la transparencia es importante.
- Los árboles de decisión pueden ser entrenados con datos etiquetados y se utilizan para predecir el resultado de nuevas instancias de datos.
- Los árboles de decisión pueden ser optimizados para mejorar su rendimiento, utilizando técnicas como poda y selección de características.

Aprendizaje Supervisado

$$y = f(\mathbf{x})$$

Buscamos un modelo **f** que permita determinar la *salida* a partir de la *entrada*

Con este modelo podremos predecir *y*, para nuevos datos **X** de los cuales no conozcamos la *salida*.

atributos X

etiquetas y: existentes para el entrenamiento, o predichas en producción

Machine Learning



Aprendizaje Supervisado




Clasificación

Modelos



- **Árbol de Decisión**
- Regresión logística
- Perceptrón
- Support Vector Machines
- k-vecinos más cercanos
- Random Forest
- etc...

Ejemplo - Pingüinos




Ejemplo - Pingüinos

¡Ojo con los colores! ¡No coinciden!




Ejemplo - Pingüinos

¡Ojo con los colores! ¡No coinciden!




Ejemplo

- Instancia con culmen_depth_mm = 19 y culmen_length_mm = 47




Ejemplo - Pingüinos




- Están conformados por nodos de decisión y nodos de respuesta (hojas).
- El número de nodos que hay que atravesar para ir desde la raíz al nodo más alejado definirá la *profundidad*.
- En cada nodo definimos una impureza, que mide el error de frenar en ese nodo.
- Un nodo se fija como hoja cuando su impureza está bajo un umbral, o cuando llegamos a una profundidad máxima.

Ejemplo - Pingüinos





- Están conformados por nodos de decisión y nodos de respuesta (hojas).
- El número de nodos que hay que atravesar para ir desde la raíz al nodo más alejado definirá la *profundidad*.
- En cada nodo definimos una impureza, que mide el error de frenar en ese nodo.
- Un nodo se fija como hoja cuando su impureza está bajo un umbral, o cuando llegamos a una profundidad máxima.
- La predicción es la clase mayoritaria (moda) de la hoja correspondiente donde “cayó” la instancia.

Ejemplo - Pingüinos



Ejemplo - Pingüinos

¡Ojo con los colores! ¡No coinciden!



CC

CRASH COURSE COMPUTER SCIENCE

34

MACHINE LEARNING

MACHINE LEARNING



Árbol de decisión

Ok, ya sabemos cual es el resultado de entrenar un árbol, cómo son las fronteras y algunas de sus características. Pero,

¿Cómo se obtiene un árbol entrenado?

Árbol de decisión

LABELED DATA

MASS	WINGSPAN	MOTH SPECIES (LABEL)
2.5	41	EMPEROR
3.7	36	EMPEROR
4.2	72	LUNA
3.2	27	EMPEROR
5.5	60	LUNA
5.1	51	EMPEROR
4.0	43	EMPEROR
3.6	40	EMPEROR
8.2	75	LUNA
7.6	82	LUNA
...	...	...

Imaginemos que tenemos este Dataset de polillas Emperador y Luna.



Árbol de decisión

LABELED DATA

MASS	WINGSPAN	MOTH SPECIES (LABEL)
2.5	41	EMPEROR
3.7	36	EMPEROR
4.2	72	LUNA
3.2	27	EMPEROR
5.5	60	LUNA
5.1	51	EMPEROR
4.0	43	EMPEROR
3.6	40	EMPEROR
8.2	75	LUNA
7.6	82	LUNA
...	...	...

Features **X**

Target **Y**

Imaginemos que tenemos este Dataset de polillas Emperador y Luna.




Árbol de decisión

LABELED DATA

MASS	WINGSPAN	MOTH SPECIES (LABEL)
2.5	41	EMPEROR
3.7	36	EMPEROR
4.2	72	LUNA
3.2	27	EMPEROR
5.5	60	LUNA
5.1	51	EMPEROR
4.0	43	EMPEROR
3.6	40	EMPEROR
8.2	75	LUNA
7.6	82	LUNA
...	...	...



Features **X**

Target **Y**



Features/Atributos

Árbol de decisión



Árbol de decisión






Gráfico de decisión




¿Por qué decimos que es Machine Learning?



Es **Machine Learning** porque estas preguntas se eligen automáticamente al entrenar el modelo, a partir de los datos **X** e **Y**.

¿Por qué decimos que es Machine Learning?




¿Cómo decide qué preguntar?

1. Impureza Gini
1. Entropía/Ganancia de información

Son cálculos que se hacen sobre los datos que ayudan a descubrir cuán bueno es un atributo para separar las instancias de acuerdo a sus etiquetas.

¿Por qué decimos que es Machine Learning?



¿Cómo decide qué preguntar?

1. Impureza Gini

1. Entropía/Ganancia de información

Son cálculos que se hacen sobre los datos que ayudan a descubrir cuán bueno es un atributo para separar las instancias de acuerdo a sus etiquetas.

Impureza Gini

Supongamos que tenemos este dataset para el ejemplo de las polillas (muy simplificado).

¿Cuál será un mejor atributo para “preguntar”?

Pero... ¿qué es un mejor atributo?

Intuitivamente, un mejor atributo será el que separe “mejor” las clases.

que las muestras obtenidas sean lo más “puras” posibles. Es decir, tengan instancias de una sola de las clases.

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini

A simple vista, es muy difícil determinar cuál atributo es mejor para separar clases, y eso que sólo tenemos diez instancias, dos atributos y solamente dos valores por atributo.

Para hacerlo eficientemente, necesitamos algún estadístico que cuantifique la pureza de las muestras.

Para eso existe la **Impureza Gini**.

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?

Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.

¿ Masa < **0.75 gr** ?

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?

Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.

¿ Masa < **0.75 gr** ?


Sí

3 Luna Moth
4 Emperor Moth

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?

Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.



Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?

Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.

¿ Envergadura < **45 mm** ?

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?

Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.

¿ Envergadura < **45 mm** ?


Sí

1 Luna Moth
4 Emperor Moth

Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth

Impureza Gini: ¿Cómo funciona?



Probemos construyendo una *pregunta* por cada feature y veamos cual deja mejor separadas las instancias.



Masa	Envergadura	Tipo de polilla
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Mayor a 0.75 gr	Menor a 45 mm	Luna Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Mayor a 0.75 gr	Mayor a 45 mm	Luna Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth
Menor a 0.75 gr	Menor a 45 mm	Emperor Moth



Impureza Gini: ¿Cómo funciona?

¿Cuál de las dos preguntas *separó* mejor las clases?



Impureza Gini: ¿Cómo funciona?

¿Cuál de las dos preguntas *separó* mejor las clases?



Si bien a simple vista nos damos una idea, hay que cuantificarlo.

Impureza Gini

1. Calculamos la **Impureza Gini inicial** de la muestra.
2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.
3. Elegimos el atributo con **mayor reducción de impureza** (Ganancia Gini).
4. Si consideramos que las instancias ya están clasificadas suficientemente bien, FIN. Si no, seguimos construyendo el árbol de forma iterativa, tomando como muestra inicial la muestra de cada hoja y realizando los pasos 1 - 4.

Impureza Gini

1. Calculamos la **Impureza Gini inicial** de la muestra:

$$Gini(S) = 1 - \sum_{c \in Clases} \left(\frac{|S_c|}{|S|} \right)^2$$

donde S_c es el conjunto de instancias que pertenecen a la clase C , S es toda la muestra. Entonces, $|S|$ es el tamaño de la muestra, mientras que $|S_c|$ es la cantidad de instancias que pertenecen a la clase C .

Impureza Gini

1. Calculamos la **Impureza Gini inicial** de la muestra.

$$Gini_{inicial} = 1 - (proporción\ de\ Luna\ Moth)^2 - (proporción\ de\ Emperor\ Moth)^2$$

Impureza Gini

1. Calculamos la **Impureza Gini inicial** de la muestra.

$$Gini_{inicial} = 1 - (\text{proporción de Luna Moth})^2 - (\text{proporción de Emperor Moth})^2$$

Como son diez instancias, (6 Luna Moth y 4 Emperor Moth), entonces:

$$Gini_{inicial} = 1 - (6/10)^2 - (4/10)^2 = 0.48$$

Impureza Gini

1. Calculamos la **Impureza Gini inicial** de la muestra.

$$Gini_{inicial} = 1 - (\text{proporción de Luna Moth})^2 - (\text{proporción de Emperor Moth})^2$$

Como son diez instancias, (6 Luna Moth y 4 Emperor Moth), entonces:

$$Gini_{inicial} = 1 - (6/10)^2 - (4/10)^2 = 0.48$$

***Si la muestra tiene solamente miembros de una clase, entonces**

$$Gini = 1 - (\text{proporción única clase})^2 = 0$$

***y si tiene mitad y mitad:**

$$Gini = 1 - (1/2)^2 - (1/2)^2 = 0.5$$

Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.

¿ Masa < **0.75 gr** ?


Sí

3 Luna Moth
4 Emperor Moth

Gini para esta **hoja**:
 $= 1 - (3/7)^2 - (4/7)^2$
 $= 0.4898$


Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.



Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.



Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.

¿ Envergadura < **45 mm** ?


Sí

1 Luna Moth
4 Emperor Moth

Gini para esta **hoja**:
 $= 1 - (1/5)^2 - (4/5)^2$
 $= 0.32$


Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.



Impureza Gini

2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.



Impureza Gini

3. Elegimos el atributo con **mayor reducción de impureza** (Ganancia Gini).

- Masa: $0.48 - 0.343 = 0.137$

- Envergadura: $0.48 - 0.16 = 0.32$

Impureza Gini

3. Elegimos el atributo con **mayor reducción de impureza** (Ganancia Gini).

- Masa: $0.48 - 0.343 = 0.137$

- **Envergadura: $0.48 - 0.16 = 0.32$**

4. Si consideramos que las instancias ya están clasificadas suficientemente bien,
FIN.

Si no, seguimos construyendo el árbol de forma iterativa, tomando como muestra inicial la muestra de cada hoja y realizando los pasos 1 - 4.

En resumen...

1. Calculamos la **Impureza Gini inicial** de la muestra.
2. Calculamos la **Impureza Gini** luego de hacer cada pregunta. Para ellos, hacemos un **promedio ponderado** de las impurezas resultantes en cada **hoja**, por pregunta.
3. Elegimos el atributo con **mayor reducción de impureza** (Ganancia Gini).
4. Si consideramos que las instancias ya están clasificadas suficientemente bien, FIN. Si no, seguimos construyendo el árbol de forma iterativa, tomando como muestra inicial la muestra de cada hoja y realizando los pasos 1 - 4.

Árboles: Algunos comentarios

1. **Entropía/ganancia de información** es otro criterio que podemos utilizar para medir el grado de impureza de una muestra y elegir el atributo que más la reduce. Conceptualmente es MUY parecido.
2. Nosotros aquí mostramos un ejemplo de **Clasificación Binaria** (dos clases). Los árboles generalizan muy bien a problemas multiclase y de regresión.
3. Los árboles de decisión son “greedy” porque eligen la mejor división en cada paso, sin considerar el impacto global en el árbol.
4. En el ejemplo, consideramos atributos solamente con dos posibles valores. Si tenemos atributos numéricos, el árbol debe probar todos los posibles umbrales*.
5. Hay mucha jerga en árboles: hojas, raíz, nodo, poda (pruning), Gini, información, profundidad, etc. Es fácil marearse. La documentación de Scikit-Learn y, sobretodo, la práctica, les servirán para ir incorporándolos.

*En la práctica no siempre es así.

Árboles: Ventajas y desventajas



- Simple de entender, interpretar y visualizar. Esto es una gran ventaja, también, al momento de comunicar nuestro trabajo.
- Entrenamiento rápido.
- Modelo base para modelos más complejos (Random Forest, xgboost, etc.).
- ¡Muchas implementaciones y variantes!



- Poder de generalización relativamente bajo en muchas circunstancias.
- Desempeño inferior a modelos más modernos.
- ¡Muchas implementaciones y variantes!

Scikit-Learn

Scikit-Learn

Convención

Filas → Instancias

LABELLED DATA

MASS	WINGSPAN	MOTH SPECIES (LABEL)
2.5	41	EMPEROR
3.7	36	EMPEROR
4.2	72	LUNA
3.2	27	EMPEROR
5.5	60	LUNA
5.1	51	EMPEROR
4.0	43	EMPEROR
3.6	40	EMPEROR
8.2	75	LUNA
7.6	82	LUNA
...	...	...

Columns → Características

Convención

Filas → Instancias

LABLED DATA		
MASS	WINGSPAN	MOTH SPECIES (LABEL)
2.5	41	EMPEROR
3.7	36	EMPEROR
4.2	72	LUNA
3.2	27	EMPEROR
5.5	60	LUNA
5.1	51	EMPEROR
4.0	43	EMPEROR
3.6	40	EMPEROR
8.2	75	LUNA
7.6	82	LUNA
...	...	...

Features **X**

Target **Y**

Columns → Características

Scikit Learn

