
Introducción al Aprendizaje Automático


1er cuatrimestre 2025



Universidad
Nacional
de San Martín

Aprendizaje no supervisado

Mapa



Solo datos

Llamamos **Aprendizaje No Supervisado** a los métodos para trabajar con datos (instancias) que no tienen asociados una etiqueta (una clase o un valor).


Las principales herramientas en Aprendizaje No Supervisado son:

- **Clustering**
- Reducción de dimensionalidad

Aprendizaje No Supervisado • Clustering

Dado un set de datos, nuestro objetivo será encontrar grupos (clusters) en los cuales las instancias pertenecientes sean parecidas (estén “cerca”).


Datos iniciales



Aprendizaje No Supervisado • Clustering


Dado un set de datos, nuestro objetivo será encontrar grupos (clusters) en los cuales las instancias pertenecientes sean parecidas (estén “cerca”).

Datos iniciales



Aprendizaje No Supervisado • Clustering

Dado un set de datos, nuestro objetivo será encontrar grupos (clusters) en los cuales las instancias pertenecientes sean parecidas (estén “cerca”).



Aprendizaje No Supervisado • Clustering

¿Para qué sirve?

Encontrar grupos en los datos
puede ayudar en problemas de:

- Investigación de mercado
- Sistemas de recomendación
- Medicina
- Biología (genética y especies)
- Muchísimas mas cosas

Aprendizaje No Supervisado • Clustering

¿Para qué sirve?

Encontrar grupos en los datos puede ayudar en problemas de:

- Investigación de mercado
- Sistemas de recomendación
- Medicina
- Biología (genética y especies)
- Muchísimas mas cosas

¿Cómo se hace?

Algunos de los algoritmos para hacer clustering son:


- K-means
- DBSCAN
- Hierarchical Clustering (aglomerativo)
- Fuzzy C-Means (como K-means pero permite overlap)
- GMM: Gaussian Mixture Models (supone distribucion gaussiana)

Aprendizaje No Supervisado

Clustering: K-Means

Clustering • K-Means

Objetivo: Separar los datos en k clusters (número dado) ubicando a las instancias que estén dentro de una región cercana dentro de un mismo cluster.



Idea: encontrar un número k de centros (centroids), uno por cada cluster, de manera tal que la distancia entre los centros y los datos más cercanos sea la mínima posible.

Luego cada instancia se identifica en el grupo del centroide más cercano.

Clustering • K-Means

¿Cómo se hace? Se utiliza un algoritmo iterativo hasta llegar al resultado.

1) Se inicializan los k Centroides.

La ubicación inicial puede ser aleatoria o con algún criterio.

2) Encontrar el centroide más cercano.

Se asigna a cada instancia al centroide más cercano (el significado de "cercano" puede cambiar, es un hiperparámetro)

3) Actualizar los centroides.


La nueva posición del centroide es el promedio de las posiciones de las instancias en ese cluster (de acá viene el means).

4) Repetir pasos 2 y 3.



Se repiten los updates hasta que la posición del centroide ya no varíe

Clustering • K-Means


1) Se inicializan los k Centroides.



2) Encontrar el centroide más cercano.



3) Actualizar los centroides.



4) Encontrar el centroide más cercano.




Clustering • K-Means



Paso 1: Seleccionar el número de clusters que se quieren obtener ($k=3$)




Paso 2: Seleccionar aleatoriamente 3 diferentes puntos



Paso 3: Medir la distancia entre el primer punto y los 3 centroides


Clustering • K-Means



Paso 4: Asignar el cluster al grupo más cercano




Paso 5: Repetimos el mismo proceso para los demás valores



Paso 6: Calcular la media de cada cluster

Clustering • K-Means



Paso 7: Repetir el mismo proceso de cálculo de distancias y asignación


Paso 8: Se puede revisar que tan bien quedo el algoritmo con lo que se conoce como la Variación total de clusters

De lo anterior se puede deducir que la elección inicial de los centroides es importante

Clustering • K-Means




Paso 9: La selección de puntos se puede cambiar



Paso 10: El proceso se repite iterativamente varias veces hasta lograr convergencia

Clustering • K-Means



Si repetimos el proceso podemos identificar cuál metodología funciona mejor **(Esto puede ser mucho mayor que 3 veces)**

Clustering • K-Means

Los resultados de K Means son:

- Los centroides de los clústeres K , que pueden ser usados para etiquetar nuevos datos.
- Etiquetas para los datos de formación, cada punto de datos se asigna a un único clúster.

Aprendizaje No Supervisado


Clustering: DBSCAN

Clustering • DBSCAN

DBSCAN = **Density-Based Spatial Clustering of Applications with Noise**


Clustering • DBSCAN

Objetivo: Identificar un número arbitrario de clusters. Los clusters estarán definidos por densidad de puntos. Puede haber puntos que no pertenezcan a ningún cluster (noise).



Clustering • DBSCAN

Objetivo: Identificar un número arbitrario de clusters. Los clusters estarán definidos por densidad de puntos. Puede haber puntos que no pertenezcan a ningún cluster (**noise = OUTLIERS**).



Idea: recorrer todo el dataset e ir identificando las zonas de puntos densamente pobladas como pertenecientes a un mismo cluster.

Los puntos aislados serán reconocidos como ruido.



Clustering • DBSCAN

¿Cómo se hace?

1) Se define una distancia epsilon (parámetro) como la vecindad de un punto. Se elige un número de puntos mínimos de para considerar un cluster minPoints (parámetro).
(Notar: no se elige el número de clusters)


Input: Puntos, min_pts, eps

Cada punto es:

Core point: tiene al menos min_pts en su vecindario

Border point: no es core pero tiene al menos 1 core point en su vecindario

Noise point: No es core o border




Clustering • DBSCAN

¿Cómo se hace?


1) Se define una distancia epsilon (parámetro) como la vecindad de un punto. Se elige un número de puntos mínimos de para considerar un cluster minPoints (parámetro).
(Notar: no se elige el número de clusters)

2) Luego se realiza el siguiente proceso sobre todos los puntos del dataset:

- 1) Se toma un punto no visitado random. Se identifica si el punto es un 'core', es decir, si tiene minPoints en su vecindario. Si no tiene, se lo llama 'noise'. Este punto se marca como visitado.
- 2) Si es un core, se le asigna un nuevo cluster y todos los puntos de su vecindario se consideran dentro de su cluster. Si alguno de estos puntos también son cores, este proceso se repite. A los puntos asignados a un cluster que no son core, se los llama 'border'. Todos se marcan como visitados.
- 3) Este proceso se repite hasta que todos los puntos hayan sido visitados.



Clustering • DBSCAN



¿Cómo se comparan
K-Means y DBSCAN?

K-Means



- Rápido, muy mucho. $O(n)$.
- No tiene parámetros
- Fácil asignar nuevas instancias



- Hay que definir el número de clusters
- Solo funciona bien con clusters tipo esferas
- Sensible a outliers (afectan el promedio)


DBSCAN

- No hay que elegir el número de clusters
- Detecta cualquier forma de clusters
- Determina automáticamente datos outliers
- Hay que elegir bien los parámetros
- No anda bien si hay clusters de diferentes densidades
- Es computacionalmente más costoso (tarda más)

Clustering • K-Means vs. DBSCAN


¿Cómo funcionan?

Es muy común ver este tipo de representaciones de los métodos, donde muestra cómo categorizan distintos datasets y cuanto tardan en hacerlo.



Clustering

Existen muchos métodos para separar en clusters!!



<https://scikit-learn.org/stable/modules/clusteri ng.html>

Aprendizaje No Supervisado

Evaluación de clusters

Evaluación: Elbow method

Buscamos una medida para la validación e interpretación de clusters en un dataset.

Idea: medimos cuál es la distancia media de cada dato al centroide más cercano.

Evaluación: Elbow method

Buscamos una medida para la validación e interpretación de clusters en un dataset.

$$d(i) = \|\mathbf{X}_i - \mathbf{C}_j\|^2$$

Distancia de
cada dato

Posición
del dato i

Posición del centroide
más cercano

Idea: medimos cuál es la distancia media de cada dato al centroide más cercano.

Evaluación: Elbow method (K-Means)

Buscamos una medida para evaluar qué tan bien resulta el “clustereo” en K-Means.

Idea: medimos cuál es la distancia media de cada dato al centroide más cercano.

Evaluación: Elbow method (K-Means)

Buscamos una medida para evaluar qué tan bien resulta el clustereo en K-Means.


$$D = \frac{1}{N} \sum_{i=1}^N d(i)$$

**Distancia
media total**

Idea: medimos cuál es la distancia media de cada dato al centroide más cercano.

Evaluación: Elbow method (K-Means)

Buscamos una medida para evaluar qué tan bien resulta el clustereo en K-Means.




Idea: medimos cuál es la distancia media de cada dato al centroide más cercano.

En sklearn: Luego de fitear el modelo, la variable 'model.inertia_' tiene esta información.

K ÓPTIMO: Buscar donde esta el 'codo' de la curva. El valor de inercia siempre descende con el número de clusters.

Evaluación: Elbow method (K-Means)




K=2 es mucho mejor que K=1 con una menor total variation


k=2



K=3 es mucho mejor que K=2 o K=1 con una mucha menor variación total



Variación total menor que K=3



Evaluación: Silhouette

Silhouette: es una medida para la validación e interpretación de clusters en un dataset (para cualquier método de clustering que hayan usado).

Definición:

$$s(i) = \begin{cases} 1 - a(i)/b(i), & \text{if } a(i) < b(i) \\ 0, & \text{if } a(i) = b(i) \\ b(i)/a(i) - 1, & \text{if } a(i) > b(i) \end{cases}$$

Idea: medimos qué tan parecidos son los los datos con su propio cluster (cohesión) en comparación con qué tan parecidos son a otros clusters (separación).

s(i): es el valor de silhouette para el dato i.

a(i): distancia media del dato i con el resto de su cluster

b(i): distancia media del dato i con el cluster más cercano

Evaluación: Silhouette

Definición:

$$s(i) = \begin{cases} 1 - a(i)/b(i), & \text{if } a(i) < b(i) \\ 0, & \text{if } a(i) = b(i) \\ b(i)/a(i) - 1, & \text{if } a(i) > b(i) \end{cases}$$

s(i): es el valor de silhouette para el dato i.

a(i): distancia media del dato i con el resto de su cluster



b(i): distancia media del dato i con el cluster más cercano

Esto nos da una medida para cada dato de qué tan bien está ubicado en los clusters. Para una medida de todo el conjunto, se toma la media de todos los s(i).

Evaluación: Silhouette

Resultados: se suele mirar el perfil de todos los datos, buscamos que sea parejo.


Silhouette analysis using $k = 4$




Evaluación: Silhouette

Resultados: se suele mirar el perfil de todos los datos, buscamos que sea parejo.

Silhouette analysis using $k = 3$




Visualization of clustered data




Evaluación: Silhouette

Resultados: se suele mirar el perfil de todos los datos, buscamos que sea parejo.

Silhouette analysis using $k = 2$



Visualization of clustered data



Otros algoritmos de Clustering

HDBSCAN

→ Variante mejorada de DBSCAN: **detecta clústeres de densidad variable** y no necesita número de grupos.

Mean Shift

→ Encuentra regiones de alta densidad sin necesidad de fijar el número de clústeres.

Agglomerative Clustering (jerárquico)

→ Construye una jerarquía de clústeres (muy útil cuando queremos entender relaciones anidadas entre grupos).

Gaussian Mixture Models (GMM)


→ Modela clústeres como distribuciones normales; útil cuando los grupos se solapan.

Spectral Clustering

→ Usa teoría de grafos para detectar agrupamientos complejos en datos no lineales.

Ejemplos: Clustering para recomendaciones para clientes

Netflix usa técnicas no supervisadas (como clustering) para agrupar usuarios según su comportamiento de visualización y sus reacciones a distintos tipos de imágenes promocionales.



Utilidad:

Predecir qué tipo de usuarios verá un título nuevo.

Diseñar imágenes de promoción personalizadas según el gusto de cada grupo.

Guiar la estrategia creativa de futuras campañas visuales.

Si te quedaste con ganas de más...

- [In Depth: k-Means Clustering](#)
- [DBSCAN: Machine Learning para detectar centros de actividad urbana](#)
- [The 5 Clustering Algorithms Data Scientists Need to Know](#)