

Correlaciones

Aplicaciones

IAA

ECyT

8 de abril de 2025



Spurious correlations

Tyler Vigen's project list

TYLER VIGEN.COM

NATIONAL
GEOGRAPHIC

ACCESO

Boletines
informativos

SUSCRIBIR



Un retrato de Nicolas Cage, un signo igual y una foto de una piscina llena de gente.

ILUSTRACIÓN FOTOGRAFÍAS DE (I) FOTOS INTERNATIONAL, GETTY (D) BERNADETT SZABO, CORBIS

CIENCIA

Curiosamente Krulwich


**Películas de Nick Cage vs.
ahogamientos y otras
correlaciones extrañas (pero
falsas)**

Correlation is not causation

Per capita consumption of margarine

correlates with

The divorce rate in Maine



◆ Per capita consumption of margarine in the United States · Source: US Department of Agriculture

● The divorce rate in Maine · Source: CDC National Vital Statistics

2000-2009, $r=0.993$, $r^2=0.985$, $p<0.01$ · tylervigen.com/spurious/correlation/5920

David Hume

No tenemos otra noción de causa y efecto que la de ciertos objetos, que siempre han estado unidos entre sí, y que en todos los casos pasados se han encontrado inseparables. ... y siempre encontramos que a partir de la conjunción constante los objetos adquieren una unión en la imaginación

Ronald Fischer

... padre de la estadística moderna y diseño experimental.

Sin embargo, con una selección de datos rechazó la idea de que fumar cigarrillos fuera peligroso y lo calificó de “propaganda”. ver David Sumpter, “Four Ways of Thinking: Statistical, Interactive, Chaotic and Complex” (2023), Penguin.

Correlaciones

La correlación se define a partir de

$$\text{Cov}(x, y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})(y_i - \bar{y})$$

donde

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

y se llega a

$$\text{Corr}(x, y) = \frac{\text{Cov}(x, y)}{\sqrt{\text{Cov}(x, x)\text{Cov}(y, y)}}$$

En regresiones

La propuesta es generar un conjunto de datos sintéticos donde los atributos tienen distinto grado de control sobre el target y algunos están relacionados.

```
import numpy as np
```

```
np.random.default_rng(seed=42)
```

```
# Muestras aleatorias de una distribución con densidad uniforme
```

```
# estandarizadas entre 0 y 1
```

```
samples = 1000
```

```
x1 = np.random.uniform(size = samples) # atributo relevante
```

```
x2 = np.random.uniform(size = samples) # atributo relevante
```

```
x3 = 0.8 * x2 + 0.2 * np.random.uniform(size = samples) # atributo relevante
```

```
x4 = 0.2 * np.random.uniform(size = samples) # atributo poco relevante
```


```
y = x1 + x2 + x3 - x4 + 0.2 * np.random.normal(size = samples)
```

```
data = np.array([x1, x2, x3, x4, y]).T
```

```
data.shape
```

En regresiones (2)


Representamos la respuesta en función de una sola variable. Suelen filtrarse los cambios en los otros atributos y manifestarse como una mayor variabilidad del target. Se debería buscar de fijar el valor de los otros atributos. . .



En regresiones (3)

La alternativa es promediar la respuesta dentro de diferentes intervalos

Realizamos una serie de cortes sobre los que ejecutaremos proemndios (factor de R).



En regresiones (4)

`corrcoef` es una función de `numpy` que devuelve la matriz de covarianza normalizada. Los valores de `Corr` van entre -1 y 1. Representamos la matriz de correlaciones como una imagen (o mapa de calor)


```
dcorr = np.corrcoef(data, rowvar=False)
```

En regresiones (5)

```
%%capture out
# Representamos la matriz de correlaciones como una imagen (o
import matplotlib as mpl
fig, ax = plt.subplots()
im = ax.imshow(dcorr, cmap=mpl.colormaps['bwr_r'], interpolation='nearest')
# Creamos colorbar
cbar = ax.figure.colorbar(im, ax=ax)
colnames = ['x1', 'x2', 'x3', 'x4', 'y']
# Mostramos los ticks y las etiquetas
ax.set_xticks(np.arange(len(colnames)), labels=colnames)
ax.set_yticks(np.arange(len(colnames)), labels=colnames)
# Rotamos 45° las etiquetas del eje x
plt.setp(ax.get_xticklabels(), rotation=45, ha="right", rotate=True)
# Anotamos los valores de las celdas
for i in np.arange(len(colnames)):
    for j in np.arange(len(colnames)):
        text = ax.text(j, i, np.round(dcorr[i, j], 2), ha="center", va="bottom")
```

En regresiones (6)

```
out.show()
```



En regresiones (7)

Observamos:

- 1 El atributo x_4 tiene poca correlación con el taret.
- 2 Los atributos x_2 y x_3 están correlacionados entre sí y con el target
- 3 El atributo x_1 también tiene buena correlación con el target (aunque algo menor).

Resultados esperables por construcción. . .

En regresiones (8)

Si vamos por los atributos “más fuertes” sin tener en cuenta las correlaciones entre ellos...

```
from sklearn.linear_model import LinearRegression
```

```
X_23 = np.array([x2, x3]).T
```

```
reg = LinearRegression().fit(X_23, y)
```

```
print('El coeficiente de determinación  $R^2$ , con x2 y x3 es: ',
```

```
X_12 = np.array([x1, x2]).T
```

```
reg = LinearRegression().fit(X_12, y)
```

```
print('El coeficiente de determinación  $R^2$ , con x1 y x2 es: ',
```

```
El coeficiente de determinación  $R^2$ , con x2 y x3 es: 0.695338
```

```
El coeficiente de determinación  $R^2$ , con x1 y x2 es: 0.878487
```

En regresiones (9)

```
%%capture out
```

```
fig, ax = plt.subplots(1,2)
ax[0].set_xlim(0,3)
ax[0].set_ylim(0,3)
ax[0].scatter(y, reg.predict(X_23))
ax[0].axline((0,0), (1, 1), linestyle='--', color='red')
ax[0].set_xlabel('x2')
ax[0].set_ylabel('x3')

ax[1].set_xlim(0,3)
ax[1].set_ylim(0,3)
ax[1].scatter(y, reg.predict(X_12))
ax[1].axline((0,0), (1, 1), linestyle='--', color='red')
ax[1].set_xlabel('x1')
ax[1].set_ylabel('x2')
```

En regresiones (10)

`out.show()`




Figure 6: Variabilidad en el ajuste según la selección de atributos

En clasificación

Vamos a generar clases sintéticas aplicando la transformación de la función sigmoide logística al problema anterior. Para ello, tomamos la función de biblioteca `scipy.special.expit`

La función `expit`, también conocida como sigmoide logística, se define como

$$\text{expit}(x) = \frac{1}{(1 + \exp(-x))}$$

Es la inversa de la función `logit`.

```
from scipy.special import expit, logit
```

```
# Restamos la media para obtener clases balanceadas
```

```
c = np.int64(expit(y-np.mean(y)) > 0.5)
```

En clasificación (2)

Al igual que en el caso anterior, calculamos las correlaciones y las representamos como una imagen (o mapa de calor)

```
ccorr = np.corrcoef(data, rowvar=False)
```


En clasificación (3)

```
%%capture out
```

```
# Código para figura...
```

En clasificación (4)

`out.show()`



En clasificación (5)

Observamos:

- 1 El atributo x_4 tiene poca correlación con el taret.
- 2 Los atributos x_2 y x_3 están correlacionados entre sí y con el target
- 3 El atributo x_1 también tiene buena correlación con el target (aunque algo menor).

Resultados esperables por construcción...

En clasificación (6)

```
%%capture out
```

```
fig, ax = plt.subplots(1,2)
ax[0].scatter(x2, x3, c=c)
ax[0].set_xlabel("x2")
ax[0].set_ylabel("x3")
ax[0].set_xlabel('x2')
ax[0].set_ylabel('x3')
```

```
ax[1].scatter(x1, x2, c=c)
ax[1].set_xlabel("x1")
ax[1].set_ylabel("x2")
ax[1].set_xlabel('x1')
ax[1].set_ylabel('x2')
```

En clasificación (7)

`out.show()`




Figure 8: Ampliación de la frontera de decisión según la selección de atributos

En clasificación (8)

Confirmamos que es una clasificación binaria con clases balanceadas

```
print("total en clase 1: ", np.sum(c))  
print("total en clase 0: ", len(c) - np.sum(c))
```

```
total en clase 1:  517  
total en clase 0:  483
```


En clasificación (9)

Vamos a comparar la exactitud (accuracy) para clasificadores según el subconjunto e atributos elegidos

```
from sklearn.linear_model import LogisticRegression

clf = LogisticRegression(random_state=42).fit(X_23, c)
print("La exactitud con x2 y x3 es : ", clf.score(X_23,c))
clf = LogisticRegression(random_state=42).fit(X_12, c)
print("La exactitud con x1 y x2 es : ", clf.score(X_12,c))
```

La exactitud con x2 y x3 es : 0.847

La exactitud con x1 y x2 es : 0.913

Las correlaciones pueden orientarnos sobre la elección de atributos,

- importa hallar las variables con correlaciones altas con el *target*

pero,

- deben tenerse en cuenta los vínculos entre atributos

y

- considerar una explicación causal admisible.