
Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín

Repaso

¿Cómo entrenamos un modelo?

En nuestro flujo de trabajo, tendremos que emular una situación donde el modelo es entrenado con ciertos datos y luego es evaluado con datos nuevos.


Antes de entrenar un modelo...

1. **Separo una porción de los datos**
2. **Evalúo el desempeño del modelo sobre esos datos. (*que nunca vio*)**

En general, los datos se separan al azar para evitar cualquier orden o estructura subyacente en los datos¹.

¹ En muchas situaciones, esto no es válido. Por ejemplo, cuando queremos entrenar un modelo que haga predicciones a futuro (datos ordenados como series temporales).

Entrenamiento general de modelos



	DSSAT-CSM	Richards
Bias	-0.7%	-0.02%
RMSE	3.7%	3.3%
EF	0.65%	0.72%


Humedad de suelo en los primeros 15cm simulada con los modelos de Richards y de Ritchie (DSSAT-CSM), y lecturas de TDR.

Lluvia acumulada diaria registrada en la estación meteorológica de Ezeiza (próxima al sitio experimental en INA), entre el 1 de Enero y el 28 de Junio de 2008.



¿Cómo lo ponemos en práctica?

¿Solución? Train-test split.



Un conjunto de N observaciones se divide aleatoriamente en subconjuntos de entrenamiento y prueba. El método de aprendizaje estadístico se ajusta al subconjunto de entrenamiento y, el desempeño, se evalúa sobre el subconjunto de prueba.


¿Se puede hacer mejor?

Evaluación II -



Validación Cruzada

¿Cuál es el desempeño?


- El modelo A es evaluado sobre el conjunto de datos de prueba (no vistos aún).
- Pero el desempeño cambia con la partición del conjunto de datos 🤔



Semilla 1




Semilla 2



Si hay otros modelos propuestos, ¿cuál es *mejor*?

- Ambos modelos deben ser evaluados sobre conjuntos de datos no vistos durante el entrenamiento.
- ¿Y si cambiamos la semilla en el train-test split?

Semilla 1



Modelo A

Exactitud: 0.76


Modelo B

Exactitud: 0.75

¿Cómo decidimos cuál modelo es *mejor*?

- ¿Es significativa esa diferencia?
- ¿Se podría hacer un uso más “simétrico” de los datos?

Semilla 2



Modelo A



Exactitud: 0.74

Modelo B

Exactitud: 0.76

Desempeño para diferentes particiones

- Potenciales problemas:
- La estimación del error de prueba puede variar mucho dependiendo de las observaciones incluidas.
- El subconjunto de prueba puede sobreestimar el error para el modelo ajustado sobre todo el conjunto.



Izq: Error de validación para una única partición en datos de entrenamiento y prueba. Der: El método de evaluación se repitió 10 veces, cada una con una partición aleatoria diferente. Esto muestra la variabilidad en la estimación del MSE en prueba.

Soluciones para la evaluación de desempeño:


Métodos de remuestreo (resampling)

- Implican extraer repetidamente muestras de un conjunto de entrenamiento y ajustar el modelo en cada iteración para obtener información adicional.
- El remuestreo puede ser *computacionalmente caro*.
- Clases de métodos:
 - ▼ **Validación cruzada (Cross-validation, CV)**
 - ✓ Estima la tasa de error de prueba reservando un subconjunto de las observaciones de entrenamiento por fuera del proceso de ajuste y luego aplica aprendizaje estadístico a esos datos retenidos.
 - ✓ **Obtiene una evaluación de desempeño de nuestro modelo que es independiente de la partición en entrenamiento y prueba de los datos.**
 - ▼ Bootstrap

Las aplicaciones de los métodos de remuestreo van más allá de ML.

Error de *out-of-bag* (OOB) para Random Forest

- Clases de métodos:
 - ▼ Bootstrap: El OOB es el error promedio calculado para las predicciones de los árboles que no tomaron esas muestras para su entrenamiento en el resampeonato con reposición.
 - ▼ Tiene cierta semejanza a CV.
 - ▼ El ejemplo muestra como puede medirse el error de OOB a medida que se agregan y entrenan nuevos árboles. (Tomado de “Elements of statistical learning”).



Validación Cruzada dejando uno afuera (LOOCV)

Se ajusta el modelo sobre $N-1$ observaciones de entrenamiento y se predice para el target (y_i) excluido.

Si bien es un estimador no sesgado,

$$MSE_i = (\hat{y}_i - y_i)^2$$

es muy variable porque se basa en una sola observación.

La estimación de LOOCV es el promedio de los N errores

$$CV_{(N)} = 1/N \sum MSE_i$$

- Tiene bajo sesgo
- Sobreestima menos el error en prueba
- Al repetir el cálculo del LOOCV, dará siempre el mismo resultado
- Caro computacionalmente (N iteraciones)

Validación Cruzada en k carpetas (*k-fold*)


Se particiona al azar en k grupos. Un grupo se reserva y las observaciones en los k-1 grupos restantes se toman para entrenar al modelo. El proceso se repite K veces.

La estimación del error de validación de k-fold CV es el promedio de los k errores

$$CV_{(k)} = 1/k \sum MSE_i$$

donde MSE_i se calcula para cada grupo de datos de validación retenido por fuera de cada iteración en el ajuste del modelo.

Solución de evaluación de desempeño con k-fold CV



Modelo → Performance 1

Modelo → Performance 2

Modelo → Performance 3

Modelo → Performance 4

Promedio

Notar que en k-fold CV cada dato aparece una vez en los datos de prueba y $k-1$ en los datos de entrenamiento.

Solución de evaluación de desempeño con k-fold CV

- 1) Desordenar los datos
- 2) Separar en k-folds (muestras) del mismo tamaño
- 3) Para cada fold que separamos:
 - a) Elegir un fold como Validation set, y los restantes K-1 folds como Train set.
 - b) Entrenar y evaluar el modelo sobre el conjunto de validación.
 - c) Guardar el resultado de la evaluación y descartar el modelo.
- 4) Obtener una medida de performance del modelo como el promedio de las K evaluaciones obtenidas en (3). También es una buena práctica incluir una medida de la varianza de las métricas obtenidas **(¿Por qué?)**.

Repasamos...

- CV busca determinar que tan bien podemos esperar que el modelo se desempeñe sobre datos independientes.
 - En general, aunque puede sobrestimar ligeramente el MSE de prueba, las diferentes estrategias de CV coinciden en detectar la mejor combinación de hiperparámetros.
- 1) ... pero entre k-fold CV vs LOOCV: ¿Cuál es la ventaja de tomar $k=5$ o $k=10$, más allá del obvio ahorro del costo computacional?
 - 2) LOOCV al emplear casi todas las observaciones tiene un sesgo menor que k-fold CV.
 - 3) LOOCV tiene varianza más alta que k-fold CV. Promedia sobre N modelos altamente correlacionados frente a k-fold CV cuyos resultados individuales pueden variar algo más.
 - 4) Es otro ejemplo del *bias-variance trade-off* asociado a la elección de k .

Consideraciones finales

- La validación cruzada es un **procedimiento de remuestreo** que se utiliza para evaluar modelos de aprendizaje automático en una muestra de datos limitada.
- El **(hiper)parámetro más importante es k** que se refiere al número de grupos en que se dividirá una muestra de datos dada.
- Es un **método popular porque es fácil de entender** y porque generalmente resulta en una **estimación *menos sesgada* o menos optimista** de la habilidad del modelo que otros métodos, como una simple división de train / test.
- **¡No siempre hay que separar al azar!** En algunos casos (por ejemplo, predicción con series de tiempo), la validación cruzada toma otra forma.
- La validación cruzada está **íntimamente relacionada con la optimización de hiperparámetros**, que veremos en el siguiente encuentro.

The background of the image is a deep black space filled with a multitude of stars. The stars vary in size, brightness, and color, including shades of white, yellow, orange, and blue. Some stars have prominent diffraction spikes, giving them a starburst appearance. The overall effect is a rich, textured cosmic scene.



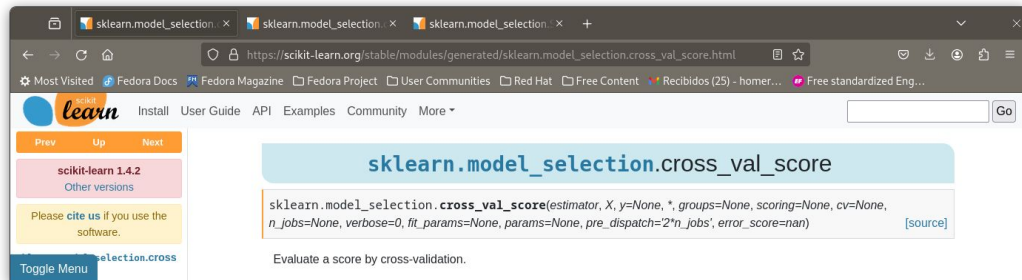
THE CODE

CV: metrics

(también cross_validate)

CV: predictions

CV: iterators



Train-Test

Conjunto de datos de Iris. Ajuste por vecinos más cercanos (KNN) para el atributo 'petal length (cm)'

CV 5-fold

