
Archivo TDS · [Seguir publicación](#)

Ciencia de datos +

Algoritmos de clasificación +

Clasificación +

Aprendizaje automático +

Comprender la curva ROC en tres pasos visuales

Lectura de 4 minutos · 12 de junio de 2020



Valeria Cortez

Seguir



Escuchar



Compartir

Uno de los conceptos que más me costó comprender en Ciencia de Datos fue la curva de características operativas del receptor (ROC). Esta es una representación visual de la eficacia de un modelo de clasificación.

En este blog, quiero explicar cómo se construye la curva ROC desde cero en tres pasos visuales.

Paso 1: Obtener las predicciones del modelo de clasificación

Cuando entrenamos un modelo de clasificación, obtenemos la probabilidad de obtener un resultado. En este caso, nuestro ejemplo será *la probabilidad de pagar un préstamo*.




Figura 1: Ejemplo de modelo de clasificación

Las probabilidades oscilan entre 0 y 1. Cuanto mayor sea el valor, mayor será la probabilidad de que la persona devuelva el préstamo.

El siguiente paso es encontrar un umbral para clasificar las probabilidades como "*pagará*" o "*no pagará*".

En el ejemplo de la Figura 1, hemos seleccionado un *umbral de 0,35* :

- Todas las predicciones iguales o superiores a este umbral se clasifican como "*rentables*".
- Todas las predicciones por debajo de este umbral se clasifican como "*no generarán ingresos*".

A continuación, analizamos cuáles de estas predicciones se clasificaron correctamente y cuáles se clasificaron erróneamente. Con esta información, podemos construir una matriz de confusión.

Todos los casos positivos reales, aquellos que *sí pagaron*, están representados por los puntos azules.

- Si se clasificaron como "*pagarán*", tenemos un verdadero positivo (TP).
- Si se clasificaron como "*no pagarán*", tenemos un falso negativo (FN).

Todos los casos negativos reales, aquellos que *no pagaron*, están representados por los puntos rojos.

- Si se clasificaron como "*no pagarán*", tenemos un verdadero negativo (VN).
- Si se clasificaron como "*reembolsarán*", tenemos un falso positivo (FP).

En la figura 2 podemos ver un resumen:

		Actuals	
		Positive	Negative
Predicted	Positive	True Positive (TP) <i>Predicted as "will repay" and "did repay" in the past</i>	False Positive (FP) <i>Predicted as "will repay", but "didn't repay" in the past</i>
	Negative	False Negative (FN) <i>Predicted as "won't repay", but "did repay" in the past</i>	True Negative (TN) <i>Predicted as "won't repay" and "didn't repay" in the past</i>

Figura 2: Matriz de confusión

Paso 2: Calcular la tasa de verdaderos positivos y la tasa de falsos positivos.

A estas alturas, ya hemos clasificado todas las predicciones y sabemos si las clasificaciones son correctas o no. Con esto, calcularemos las dos métricas siguientes:

$$\begin{aligned} \text{True Positive Rate (TPR)} \\ \text{also called sensitivity/recall/hit rate} &= \frac{TP}{P} = \frac{TP}{TP + FN} \\ \\ \text{False Positive Rate (FPR)} \\ \text{also called fall out} &= \frac{FP}{N} = \frac{FP}{FP + TN} \end{aligned}$$

Figura 3: cálculos para TPR y FPR

- Tasa de verdaderos positivos (TPR): *de todas las personas que "sí pagaron" en el pasado, ¿qué porcentaje clasificamos correctamente?*
- Tasa de falsos positivos (TFP): *de todas las personas que "no pagaron" en el pasado, ¿qué porcentaje clasificamos erróneamente?*

En la figura 3 podemos ver las fórmulas para estos cálculos.

Recibe las historias de Valeria Cortez en tu bandeja de entrada.

Regístrate gratis en Medium para recibir actualizaciones de este autor.

Introduce tu correo electrónico

Suscribir



Recuérdame para iniciar sesión más rápido.

Más abajo, en el segundo gráfico de la Figura 4, podemos ver nuestro ejemplo original en el umbral de 0,35. En este punto,

- Clasificó correctamente el 90% de todos los positivos, aquellos que *"devolvieron"* (TPR).
- Se clasificó erróneamente el 40% de todos los casos negativos, aquellos que *"no devolvieron el dinero"* (FPR).

Podemos observar que los resultados para TPR y FPR disminuyen a medida que el umbral aumenta. Si observamos el primero, donde el umbral es 0:

- Todos los positivos fueron clasificados correctamente, por lo tanto, $TPR = 100\%$.
- Todos los resultados negativos fueron clasificados erróneamente, por lo tanto, $FPR = 100\%$.

En el último ejemplo gráfico, donde el umbral está en 1:

- Todos los casos positivos fueron clasificados erróneamente, por lo tanto, $TPR = 0\%$.
- Todos los resultados negativos se clasificaron correctamente, por lo tanto, $FPR = 0\%$.




Figura 4: Resultados de FPR y TPR para diferentes umbrales de corte.

En general, podemos ver que se trata de una compensación. A medida que aumentamos nuestro umbral, clasificaremos mejor los negativos, pero esto se produce a costa de clasificar erróneamente más positivos.

Paso 3: Graficar el TPR y el FPR para cada punto de corte.

Para trazar la curva ROC, necesitamos calcular el TPR y el FPR para muchos umbrales diferentes (*este paso está incluido en todas las bibliotecas relevantes como `scikit-learn`*).

Para cada umbral, representamos gráficamente el valor de FPR en el eje x y el valor de TPR en el eje y. Luego unimos los puntos con una línea. ¡Eso es todo!

En la figura 5, podemos ver cómo cada punto de la curva ROC representa la FPR y la TRP de una clasificación en un punto de corte determinado.

Observe cómo el umbral en 1 lleva al primer punto en (0, 0) y el umbral en 0 lleva al último punto en (1, 1).




Figura 5: Ejemplo de curva ROC

El área que queda por debajo de la línea se denomina «Área bajo la curva (AUC)». Esta se utiliza para evaluar el rendimiento de un modelo de clasificación. Cuanto mayor sea el AUC, mejor será el modelo para distinguir entre clases.

Eso significa que, en un mundo ideal, nos gustaría que nuestra línea cubriera la mayor parte de la esquina superior izquierda del gráfico para obtener un AUC más alto.

• • •

Gracias por leer hasta el final 🎉

¡Espero que este blog te resulte útil! Por favor, deja tus comentarios y opiniones a continuación 🙌

Ciencia de datos +

Algoritmos de clasificación +

Clasificación +

Aprendizaje automático +



Seguir

Publicado en el archivo de TDS

828 mil seguidores · Última publicación: 3 de febrero de 2025

Archivo de artículos sobre ciencia de datos, análisis de datos, ingeniería de datos, aprendizaje automático e inteligencia artificial procedentes de la antigua publicación Towards Data Science en Medium.



Seguir

Escrito por Valeria Cortez

343 seguidores · 81 siguientes

Científico de datos principal en Monzo Bank