
Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín

Equipo Docente

- Homero Lozza - fhomero@unsam.edu.ar
- Juan Doppler - jdoppler@unsam.edu.ar
- Esteban Roitberg - eroitberg@unsam.edu.ar
- Luna Schteingart - lschteingart@estudiantes.unsam.edu.ar
- Francisco González Bianco - fgonzalezbianco@estudiantes.unsam.edu.ar

Canales de Comunicación y Links

- **Campus Virtual ECyT**

- <https://campusvirtualecyt.unsam.edu.ar/course/>

- **Discord**

- <https://discord.gg/gh2ftUc57J>



- **Clases Virtuales**

- Las clases virtuales se dictarán por Google Meet o Zoom. El link se enviará unos minutos antes por Discord.

Contenidos de la Materia: Parte I

- Conceptos Generales: Tipos de ML, regresión y clasificación, EDA, estructura de un proyecto de ML end-to-end.
- Modelos para clasificación: árboles de decisión, regresión logística.
- Modelos para regresión: regresión lineal, extensiones de la regresión lineal, árboles aplicados a regresión.
- Evaluación en problemas de clasificación y regresión. Train-test split. Validación cruzada. Métricas.
- Dicotomía Sesgo y Varianza
- Ensamblés
- Preprocesamiento

Contenidos de la Materia: Parte II

- Regularización. Selección de atributos.
- Optimización de Hiperparámetros
- Más modelos: Naive Bayes, LDA, KNN, SVM.
- Evaluación en problemas de clasificación II: clasificación desbalanceada, curva ROC, umbrales de decisión.
- Aprendizaje no supervisado: clustering

Evaluación

Parcial presencial

- Viernes 2025-04-25
- Individual
- Cubre los temas de la primera parte (es decir, hasta la clase anterior al parcial).
- Escrito y Conceptual (no hay que programar)
- Tiene un recuperatorio el martes 2025-06-17, que incluye todos los temas de la materia.

Trabajo Práctico

- En grupos de 2 ó 3 integrantes (no más, no menos).
- Fecha límite para definir el grupo: viernes 2025-04-04 – Última Hora (UH)
- Tiene dos preentregas: la primera viernes 2025-04-11 (UH) y la segunda viernes 2025-05-23 (UH)
- **Evaluación Final:** Presentación oral de 15/20 minutos + 5 de preguntas, los viernes 6 y 13 de junio + Entrega de Notebook con resolución. (Presencial para todos)
- Nota del TP: 20% preentrega 1 + 30% preentrega 2 + 50% Evaluación Final
- De ser necesario, se recupera de manera individual o grupal el viernes 2025-06-17.

Evaluación

Nota Final: 50% parcial presencial + 50% Trabajo Práctico Final

- Se deben aprobar ambas instancias para regularizar (promocionar ó estar en condiciones de dar el final) la materia. Se aprueba con 6 (60%).
- Para promocionar, se deben aprobar **todas las instancias** con nota ≥ 7 y aprobar el examen virtual del 2025-05-27.
- Nota del recuperatorio pisa nota original.
- Se debe aprobar el requisito de asistencia para regularizar (ver diapositiva siguiente)

Asistencia

- Al comienzo de cada clase presencial, se les proveerá un link a un formulario con preguntas relacionadas a la clase.
- Debe ser completado con el mail de la UNSAM (con el que están inscriptos)
- Tiempo límite: 19:00 del martes siguiente (antes de la clase virtual siguiente)
- Para regularizar se deberá haber presentado $\geq 70\%$ de los formularios (7 de 10)
- Este requisito reemplaza la asistencia.

Fechas importantes

- 2025-04-04 Definición de grupos
- 2025-04-11 Primera entrega TP
- 2025-04-25 Primer parcial (presencial)
- 2025-05-23 Segunda entrega TP
- 2025-05-27 Segundo parcial (virtual) (martes)
- 2025-06-06 Exposiciones TP
- 2025-06-13 Exposiciones TP
- 2025-06-17 Recuperatorios

March						
Su	Mo	Tu	We	Th	Fr	Sa
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30	31					

April						
Su	Mo	Tu	We	Th	Fr	Sa
		1	2	3	4	5
6	7	8	9	10	11	12
13	14	15	16	17	18	19
20	21	22	23	24	25	26
27	28	29	30			

May						
Su	Mo	Tu	We	Th	Fr	Sa
					1	2
4	5	6	7	8	9	10
11	12	13	14	15	16	17
18	19	20	21	22	23	24
25	26	27	28	29	30	31

June						
Su	Mo	Tu	We	Th	Fr	Sa
1	2	3	4	5	6	7
8	9	10	11	12	13	14
15	16	17	18	19	20	21
22	23	24	25	26	27	28
29	30					

Otros

- No se toma asistencia en las clases virtuales.
- Las clases virtuales no se graban.
- Vamos a intentar que tanto las clases presenciales como las virtuales sean **participativas y prácticas**.

Bibliografía Recomendada

- [An Introduction to Statistical Learning](#). Versión en Python. PDF disponible libremente en la página.
- *The Data Science Design Manual*, de Steven S. Skienna.
- *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*, Aurélien Géron. Hay versión en Español.
- [Python Data Science Handbook](#). No es tanto un libro como una colección de recetas. Sin embargo, muy útil y con muy buenos ejemplos.

Además,

- *big data*, de Walter Sosa Escudero - Libro Divulgativo / Introductorio pero cercano a los contenidos de la carrera.




¿Qué es el Aprendizaje Automático?

Enfoque Uno

Ejemplo clásico

SPAM DETECTION



¿Cual de estos mails parece ser spam?

Hola Juan,

Soy Pedro, el socio del proyecto inmobiliario. Quería avisarte que la reunión del jueves se pasó para el viernes.

Saludos,
Pedro.

Hola juan_86,

Soy Namubi, príncipe de Nigeria. Preciso que mande su numero de cuenta bancaria y contraseña para transferir herencia millonaria.


Caricias significativas,
Namubi

¿Como distinguieron Spam de no Spam?

No es una tarea sencilla de realizar, de hecho hoy en día mucha gente es víctima de publicidad engañosa o estafas por medio de mails.


La tarea implica un procesamiento de alto nivel de abstracción (saber leer, relacionar conceptos, etc...), por lo cual resulta difícil programar explícitamente un algoritmo que la realice.

Algoritmo de detección de spam



Este podría ser el resultado de un desarrollo de software tradicional o a partir del uso de aprendizaje automático. Entonces, ¿en qué se diferencian?


Software Tradicional



**Inferencia /
predicción**

Desarrollo

Aprendizaje Automático



Resumiendo: en Aprendizaje Automático, las “reglas” se aprenden automáticamente (valga la redundancia). No tenemos que programarlas.

Aprendizaje Automático

¿Y cómo aprendemos esas “reglas”? A partir de datos.

Un programa de computación se dice que aprende de una experiencia E con respecto a una tarea T y una métrica de performance P , si la performance sobre T , medida por P , mejora con la experiencia E .

- Tom Mitchell, 1997

Aprendizaje Automático (supervisado) es un tipo de Inteligencia Artificial que aprende a transformar A en B , o inputs en outputs.

- Andrew Ng, 2019

Aprendizaje Automático

¿Y cómo aprendemos esas “reglas”? A partir de datos.

Un programa de computación se dice que aprende de una experiencia E con respecto a una tarea T y una métrica de performance P , si la performance sobre T , medida por P , mejora con la experiencia E .

- Tom Mitchell, 1997

Es decir, un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.

Aprendizaje Automático

¿Y cómo aprendemos esas “reglas”? A partir de datos.

Un programa de computación se dice que aprende de una experiencia E con respecto a una tarea T y una métrica de performance P , si la performance sobre T , medida por P , mejora con la experiencia E .

- Tom Mitchell, 1997

Es decir, un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.

- Tarea
- Medida de desempeño
- Experiencia



Aprendizaje Automático

Un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.



Ejemplo:

- **Tarea:** Detección de Spam
- **Medida de desempeño:** porcentaje de correos electrónicos que eran *spam*, correctamente identificados como *spam*
- **Experiencia:** base de datos de correos electrónicos, con etiquetas indicando si eran o no Spam.

Otro ejemplo


Enfoque Dos

Pingüinos del archipiélago Palmer





[Fuente](#)


Pingüinos del archipiélago Palmer



Pingüinos del archipiélago Palmer




Pingüinos del archipiélago Palmer




- ¿Qué podemos hacer para diferenciarlos?
- ¿Qué características diferencian a las especies?

¿Qué podemos hacer para diferenciarlos?




Opción 1, bien moderna: conseguir muchas imágenes de cada especie, y entrenar una red neuronal profunda que aprenda a diferenciarlas.

¿Qué podemos hacer para diferenciarlos?






¿Qué podemos hacer para diferenciarlos?




Opción 2, un poco más tradicional:
¡Obtener características o atributos!
Por ejemplo, peso, talla, ¿características del pico?



Note: In the raw data, bill dimensions are recorded as "culmen length" and "culmen depth". The culmen is the dorsal ridge atop the bill.

Pingüinos del archipiélago Palmer



- ¿Qué podemos hacer para diferenciarlos?
- ¿Qué características diferencian a las especies?

¡Ambas preguntas suelen responderse a la vez!

¿Qué podemos hacer para diferenciarlos?



[IAA_Clase_1_Demo.ipynb](#)

Aprendizaje Automático

Un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.

Ejemplo:

- **Tarea:** Identificar a qué especie pertenece un pingüino.
- **Medida de desempeño:** Porcentaje de aciertos sobre el total de aciertos y desaciertos
- **Experiencia:**
 - Base de datos de características de pingüinos con la etiqueta de a qué especie corresponden.
 - Base de datos de imágenes fotográficas de pingüinos con la etiqueta de a qué especie corresponden.

Aprendizaje Automático

Un programa aprende una tarea, si su desempeño (performance) mejora con la experiencia.

Ejemplo:

- **Tarea:** Identificar a qué especie pertenece un pingüino.
- **Medida de desempeño:** Porcentaje de aciertos sobre el total de aciertos y desaciertos
- **Experiencia:**
 - Base de datos de características de pingüinos con la etiqueta de a qué especie corresponden.
 - Base de datos de imágenes fotográficas de pingüinos con la etiqueta de a qué especie corresponden.
 - ¿Se les ocurren otras “experiencias”?

Aprendizaje Automático

Un poco de formalismo

Solemos contar con un conjunto de datos, compuesto de diferentes mediciones - características - sobre cierto número de *instancias*. En general, buscaremos predecir una de esas características, que será el target o *output* y . → Paradigma supervisado

- Si y es continua, es un problema de regresión.
- Si y es categórica, es un problema de clasificación.

El conjunto de características que utilizaremos para predecir y lo solemos notar $\mathbf{X}$.

- $\mathbf{X}$: atributos (features) o *inputs* .

En general, son más de uno. Cada atributo es una columna, y cada instancia una fila, por lo que $\mathbf{X}$ suele ser una matriz.

Un poco de formalismo

- **X**: atributos (features) o *inputs* .
- *y*: target, etiquetas, *output*.

Asumimos que existe una relación entre ellos de la forma

$$y = f(x) + \varepsilon$$

f es una función desconocida - la que queremos **estimar** -, mientras que ε es el *error*.

- La aproximación que haremos de *f* - nuestro modelo - se suele notar $\hat{f}(X)$.
- Existen muchísimas estrategias para aproximar *f*, cada una dando como resultados distintos modelos.

Un poco de formalismo

- **X**: atributos (features) o *inputs* .
- **y**: target, etiquetas, *output*.

Asumimos que existe una relación entre ellos de la forma

$$y = f(x) + \varepsilon$$

f es una función desconocida - la que queremos **estimar** -, mientras que ε es el *error*.

- La aproximación que haremos de f - nuestro modelo - se suele notar $\hat{f}(X)$.
- Existen muchísimas estrategias para aproximar f , cada una dando como resultados distintos modelos.

¿Para qué queremos obtener un modelo?

Inferencia y predicción

Predicción

Atributos (**X**, *inputs*) fácilmente conseguibles, pero no así las etiquetas (*y*, *outputs*)

→ Usamos el modelo para obtener *y*.

Ejemplo.

- **X**: variables medidas en un análisis de sangre
- *y*: embarazo o no

Inferencia y predicción

Predicción

Atributos (**X**, *inputs*) fácilmente conseguibles, pero no así las etiquetas (*y*, *outputs*)

→ Usamos el modelo para obtener *y*.

Ejemplo.

- **X**: variables medidas en un análisis de sangre
- *y*: embarazo o no

Inferencia


Nos interesa entender la relación entre **X** e *y*, no necesariamente para hacer predicciones.

¿Cuáles predictores - elementos de **X** - están asociados con *y*? ¿Cuál es esa relación? ¿Es lineal? ¿Es más compleja?


Ejemplo.

- **X**: variables medidas en un análisis de sangre y otros estudios clínicos.
- *y*: diagnóstico de una enfermedad rara.


Ciclo de vida de un proyecto de Aprendizaje Automático



Ciclo de vida de un proyecto de Aprendizaje Automático



Ciclo de vida de un proyecto de Aprendizaje Automático



Bibliografía

- [*An Introduction to Statistical Learning*](#). Capítulos 1 y 2.
- *The Data Science Design Manual*, de Steven S. Skiena. Capítulos 1 y 7.