

Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín

Mapa



Si venían un poco perdidos hasta ahora,
**¡bienvenidos al barco de
Aprendizaje No Supervisado!**



Llamamos **Aprendizaje No Supervisado** a los métodos para trabajar con datos (instancias) que no tienen asociados una etiqueta (una clase o un valor).

A diferencia del **Aprendizaje Supervisado**, el objetivo ya no pasa por predecir la etiqueta, sino por encontrar **patrones en el set de datos.**

Aprendizaje No Supervisado


Llamamos **Aprendizaje No Supervisado** a los métodos para trabajar con datos (instancias) que no tienen asociados una etiqueta (una clase o un valor).

Las principales herramientas en Aprendizaje No Supervisado son:

- **Clustering**
- **Reducción de dimensionalidad**

Supervisado	No Supervisado
Predice etiquetas conocidas	Descubre patrones sin etiquetas
Ej.: clasificar spam/no spam	Ej.: encontrar temas comunes en correos
Necesita datos etiquetados	Solo necesita características (X)

No Supervisado





 **Recomendaciones** a usuario según comportamiento pasado



 **Detección de eventos atípicos:** blooms de algas, incendios, derrames.

 **Análisis de relaciones** sin clasificaciones previas.



 **Agrupación de canciones** por características sonoras (tempo, energía...).  **Segmentación de oyentes** por hábitos (relajante vs energética).



 **Compresión (Reducción de dimensionalidad) y agrupamiento de imágenes** (radiografías, tomografías).  Identificación de anomalías (ej: tumores).

Aprendizaje No Supervisado

Llamamos **Aprendizaje No Supervisado** a los métodos para trabajar con datos (instancias) que no tienen asociados una etiqueta (una clase o un valor).

Las principales herramientas en Aprendizaje No Supervisado son:

- Clustering
- **Reducción de dimensionalidad**

Aprendizaje No Supervisado • Reducción de la dimensionalidad

¿Para qué sirve?

Reducir la cantidad de features en un dataset puede servir para:

- Reducir el input en un modelo de regresión o clasificación
- Visualización
- Detectar features relevantes en datasets
- Muchísimas mas cosas

¿Cómo se hace?

Algunos de los métodos de reducción de dimensionalidad son:


- PCA: Principal Component Analysis
- MDS: Multidimensional scaling
- t-SNE: t-distributed Stochastic Neighbor Embedding
- Auto-Encoders (Se hace con Redes Neuronales)
- LDA: Linear Discriminant Analysis (si hay etiquetas de clases)

PCA - Análisis de Componentes Principales

Análisis de componentes principales es una herramienta utilizada para la visualización de datos o el preprocesamiento de datos antes de aplicar técnicas supervisadas.

Maldición de la dimensionalidad


Maldición de la dimensionalidad



2D

V: Área = $L \times L = L^2$

Maldición de la dimensionalidad




2D

$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95L)^2$$

$$V: \text{Área} = 0.9025 L^2$$

Maldición de la dimensionalidad




2D

$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95 L)^2$$

$$V: \text{Área} = 0.9025 L^2$$

Maldición de la dimensionalidad



2D


$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95 L)^2$$

$$V: \text{Área} = 0.9025 L^2$$

$$V = (V - V)$$

Maldición de la dimensionalidad



2D

$$V: \text{Área} = L \times L = L^2$$


$$V': \text{Área} = (0.95L)^2$$

$$V': \text{Área} = 0.9025L^2$$

$$V' = (V - V')$$

$$V'/V = (V - V')/V$$

Maldición de la dimensionalidad



2D

$$V: \text{Área} = L \times L = L^2$$

$$V': \text{Área} = (0.95 L)^2$$

$$V': \text{Área} = 0.9025 L^2$$


$$V' = (V - V'')$$

$$V'/V = (V - V'')/V$$

$$V'/V = 1 - V''/V$$

$$= 1 - 0.95^2 = 0.0975 \rightarrow \text{Borde ocupa un 9\%}$$

Maldición de la dimensionalidad



2D

$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95L)^2$$

$$V: \text{Área} = 0.9025 L^2$$

$$V = (V - V)$$

$$V/V = (V - V)/V$$

$$V/V = 1 - V/V$$
$$= 1 - 0.95^2 = 0.0975$$

3D


$$V = L \times L \times L = L^3$$

$$V = 0.8574 L^3$$

$$V/V = (V - V)/V$$

$$V/V = 1 - V/V$$
$$= 1 - 0.95^3 = 0.1426 \rightarrow \text{Borde ocupa un 14\%}$$

Maldición de la dimensionalidad



2D

$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95 L)^2$$

$$V: \text{Área} = 0.9025 L^2$$

$$V = (V - V)$$

$$V/V = (V - V)/V$$

$$V/V = 1 - V/V$$

$$= 1 - 0.95^2 = 0.0975 \rightarrow \text{Borde ocupa un 9\%}$$

3D

$$V = L \times L \times L = L^3$$

$$V = 0.8574 L^3$$

$$V/V = (V - V)/V$$


$$V/V = 1 - V/V$$

$$= 1 - 0.95^3 = 0.1426 \rightarrow \text{Borde ocupa un 14\%}$$

En 10 dimensiones:

$$V/V = 0.5987 \rightarrow \text{Borde ocupa un 60\%}$$

Maldición de la dimensionalidad



2D

$$V: \text{Área} = L \times L = L^2$$

$$V: \text{Área} = (0.95L)^2$$

$$V: \text{Área} = 0.9025L^2$$

$$V = (V - V)$$

$$V/V = (V - V)/V$$

$$V/V = 1 - V/V$$

$$= 1 - 0.95^2 = 0.0975$$

3D


$$V = L \times L \times L = L^3$$

$$V = 0.8574L^3$$


$$V/V = (V - V)/V$$

$$V/V = 1 - V/V$$

$$= 1 - 0.95^3 = 0.1426$$



Maldición de la dimensionalidad




1. El volumen del espacio aumenta exponencialmente, lo que hace que los datos disponibles se vuelvan escasos y dispersos.
2. **Problemas estadísticos:** Se necesita exponencialmente más datos para obtener una estimación estadísticamente sólida.
3. **Problemas de distancia:** En altas dimensiones, las distancias entre puntos tienden a parecerse, lo que puede ser problemático para algoritmos basados en distancia, como kNN.
4. **Dificultad computacional:** Los algoritmos pueden volverse significativamente más lentos y requieren más recursos a medida que aumenta la dimensión.
5. **Dificultad para visualizar:** Es complicado visualizar y entender datos en dimensiones superiores a tres.
6. **Riesgo de sobreajuste:** Con más características, los modelos pueden adaptarse demasiado a los datos de entrenamiento y perder capacidad de generalización.
7. **Correlación entre atributos:** Pueden haber atributos redundantes o altamente correlacionados que no aporten información nueva.
8. **Dificultad en la interpretación:** Más atributos pueden llevar a modelos más complejos, que son más difíciles de interpretar.

Análisis de Componentes Principales


Aprendizaje No Supervisado • Reducción de la dimensionalidad

Buscamos reducir la cantidad de features de un dataset, pero reteniendo la mayor cantidad de “información” posible.




PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.




PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.





PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.





PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.



PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.



$$PC2 = 0.906 x_1 - 0.423 x_2$$

Notar que:



- $0.906^2 + 0.423^2 = 1$
- $-0.423 * 0.906 + (-0.906) * (-0.423) = 0$

$$PC1 = -0.423 x_1 - 0.906 x_2$$

PCA

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.

¿Y si hubiera etiquetas?



¿Cómo se calcula?

- Idea: buscar direcciones de mayor “variación” en los datos.
- Esas direcciones van a ser nuestros nuevos atributos. ¿Cómo? Como combinación lineal de los atributos originales.

X_i : atributos

$$S = \begin{bmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \cdots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \cdots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \cdots & \text{Var}(X_n) \end{bmatrix}$$

Matriz de Covarianza

- Las componentes principales se obtienen como las soluciones de $\mathbf{S}\mathbf{u} = \lambda\mathbf{u}$, con la condición de que $\mathbf{u}^T\mathbf{u}=1$. Es decir, son los autovectores de $\mathbf{S}$.
- λ (autovalor) está asociado a la proporción de varianza explicada.

Resumen PC

Es una técnica utilizada para la identificación de un número más pequeño de variables no correlacionadas conocidas como componentes principales de un conjunto más grande de datos. Permite enfatizar la variación y capturar patrones fuertes en un conjunto de datos.

Limitaciones PCA

Linealidad: solo capta relaciones lineales entre variables.

Difícil de interpretar: los componentes son combinaciones de variables, no siempre intuitivas.

Sensibilidad al escalado: variables en diferentes unidades afectan desproporcionadamente los resultados si no se normalizan.

Sensibilidad a outliers: los valores extremos pueden desviar los componentes y alterar los patrones reales.

No conserva relaciones locales (cercanías entre puntos similares en el espacio original).

Otros algoritmos de reducción de dimensionalidad

t-SNE → Visualización de agrupamientos en 2D o 3D (ideal para datos complejos, como imágenes o genética).

UMAP → Visualización preservando estructura local y global (más rápido y estable que t-SNE).

Autoencoders → Compresión de datos complejos usando redes neuronales (imágenes, texto, señales).

Isomap → Reducción manteniendo distancias geodésicas (datos con estructuras no lineales).

MDS (Multidimensional Scaling) → Visualización manteniendo distancias entre puntos.

Ejemplos: Reducción de dimensionalidad de imagenes con PCA

Una foto puede tener miles de píxeles como variables. PCA permite:

Extraer los patrones más importantes de la imagen

Reducir del número de variables

Trabajar con muchas variables es pesado.

Es difícil visualizar o entrenar modelos con tantas dimensiones.

MNIST


Dataset con 70.000 imágenes de dígitos manuscritos del 0 al 9.

Cada imagen tiene 28x28 píxeles = 784 variables.

Trabajar con 784 variables es pesado.

Es difícil visualizar o entrenar modelos con tantas dimensiones.

→ Aplicación de PCA: Reduce esas 784 variables a x componentes principales.



El gráfico muestra cuánta **varianza acumulada** se explica a medida que se agregan más componentes principales.

Podemos ver que con **alrededor de 300 componentes** ya se explica casi el **95% de la varianza total**, lo que significa que podemos reducir de 784 a muchas menos dimensiones **sin perder demasiada información**.

Ejemplos: Preparación de datos para clusterización posterior

Reducir la dimensión para posteriormente utilizar una clusterización

PCA (lineal, rápido)

t-SNE / UMAP (no lineales, capturan relaciones más complejas)

Ejemplo práctico: Spotify (análisis de canciones)

Spotify tiene millones de canciones con variables como:

Tempo, Energía, Danza, Instrumentalidad, Popularidad

Reduciendo la dimensión puede luego aplicar por técnicas de clusterización

Ejemplos: Visualización e interpretación de relaciones entre variables

Ejemplo práctico: Monitoreo de calidad del agua. Visualizar en 2D o 3D cómo se relacionan los sitios de monitoreo o los períodos de muestreo.

Dataset: Datos fisicoquímicos de calidad de agua en distintas estaciones: pH, Conductividad, Oxígeno disuelto, Nitratos, Fósforo, Temperatura

PCA permite ver si:

- Hay agrupamientos por zona geográfica (ríos más contaminados)
- Se detectan patrones temporales/condicionales (seco/húmedo)
- Hay anomalías (estaciones que se salen del grupo)

