

Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín


Transformación de Datos



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%

Fuente: ["Cleaning Big Data: Most Time-Consuming, Least Enjoyable Data Science Task, Survey Says"](#)



What's the least enjoyable part of data science?

- Building training sets: 10%
- Cleaning and organizing data: 57%
- Collecting data sets: 21%
- Mining data for patterns: 3%
- Refining algorithms: 4%
- Other: 5%

Valores Atípicos

Valores Atípicos

¿Qué es un
Outlier?
¿Por qué
ocurren?

OUTLIER = valor atípico que difiere
significativamente del resto de las
observaciones.

¿Por qué difiere?

- Error de medición del instrumento.
- Error al introducir un dato.
- Estamos trabajando con muestras/poblaciones que no son tan homogéneas como creíamos.

¿Qué es un
Outlier?
¿Por qué
ocurren?

¡Muchas veces los **OUTLIERS** son una manifestación del proceso que estamos estudiando!

Ejemplos:

- Transacción fraudulenta con una tarjeta de crédito.
- Persona enferma en un conjunto de personas sanas.
- Mayor incidencia de una enfermedad en una ciudad.
¿Esperable o outlier?

SUGERENCIA

Siempre es importante
pensar por qué hay un
outlier en nuestro dataset

Tipos de valores atípicos

univariante

Se desvía de los valores típicos de un atributo (columna)

multivariante

Se desvía de los valores típicos que hay en la relación entre dos o más columnas

Los valores atípicos suelen *confundir* la estadística que hacemos sobre los datos, ya que nos indican que no estamos trabajando con poblaciones homogéneas.

Tipos de valores atípicos

univariante

Se desvía de los valores típicos de un feature (columna)



¡Trabajaremos con estos!

multivariante

Se desvía de los valores típicos que hay en la relación entre dos o más columnas

Los valores atípicos suelen *confundir* la estadística que hacemos sobre los datos, ya que nos indican que no estamos trabajando con poblaciones homogéneas.

A veces, **detectar outliers** es el objetivo de nuestro estudio.

¿Cómo detectar outliers?

Muchas veces no existe una manera *obvia* de detectar outliers, y, en general, ¡depende del problema!

Algunas técnicas son

- Visualización: Boxplots
- Por rango intercuartílico (Interquartile Range)
- Regla de las tres sigmas
- ¡Y más!


Boxplot

Rango intercuartílico

Regla de las tres sigmas

El **diagrama de cajas** es una forma de visualizar un conjunto de valores.

Muchas veces resulta más **informativo** que simplemente dibujar un punto por cada valor, ya que nos permite tener una idea de como es la distribución subyacente.




Elegimos un valor mínimo y un valor máximo para los valores “permitidos”.

Marcamos como outliers aquellos valores que estén por debajo del mínimo o por arriba del máximo.

¿Cómo elegimos el mínimo y el máximo?


- A veces, es la variable la que nos lo indica. Por ejemplo, la asistencia a un curso no puede ser menor que cero o mayor al número de alumnos que tiene el curso.
- Un criterio estandarizado es usar
mínimo = $Q1 - 1.5 \times IQR$
máximo = $Q3 + 1.5 \times IQR$



¿Y si en lugar de usar los cuartiles
usamos las desviaciones estándar?

mínimo = valor medio - 3 x SD


máximo = valor medio + 3 x SD



Boxplot

Rango intercuartílico

Regla de las tres sigmas




Todos los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.


Boxplot

Rango intercuartílico


Regla de las tres sigmas



Todos los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.



Todos los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.




Todos los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.

Boxplot

Rango intercuartílico

Regla de las tres sigmas



Todos los valores que estén a distancia mayor a tres desviaciones estándar de la media son seleccionados como outliers.

Valores Faltantes

Valores Faltantes

¿Por qué hay valores faltantes?

Los motivos pueden ser varios: alguien se olvidó de anotar un dato o lo borró sin querer, tal vez en una encuesta una persona no quiso responder a una pregunta, o bien cambia el protocolo con el que adquirimos los datos, cambian las preguntas que hacemos o los datos que anotamos, etc.

Los tres mecanismos más generales son:

1. **Missing Completely At Random (MCAR):** en este caso, la probabilidad de tener un dato faltante, $P(\text{missing})$, es la misma para todas las instancias y no depende de las medidas de la variable de interés que estemos estudiando u otras variables.
2. **Missing At Random (MAR):** $P(\text{missing})$ no depende del valor faltante, pero sí de otras variables observables. Por ejemplo, la pregunta "¿Cuánto gana?" en una encuesta tal vez no es respondida porque el/la encuestado/a considera la pregunta inapropiada, independientemente del monto que perciba.
3. **Missing Not At Random (MNAR):** en este caso, $P(\text{missing})$ depende de la variable que queremos medir. Por ejemplo, la pregunta "¿Cuánto gana?" en una encuesta tal vez no es respondida porque el/la encuestado/a no quiere revelar su sueldo, ya sea porque lo considera muy bajo o muy alto.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing Completely At Random (MCAR):** en este caso, la probabilidad de tener un dato faltante, $P(\text{missing})$, es la misma para todas las instancias y no depende de las medidas de la variable de interés que estemos estudiando u otras variables. ¿Qué quiere decir esto? Si pensamos en una encuesta, corresponde a que el/la encuestador/a se olvide de hacer una pregunta, o pierda hojas con respuestas, es decir, algo que sucede completamente por azar. En general, esta situación es muy poco frecuente.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing Completely At Random (MCAR):** en este caso, la probabilidad de tener un dato faltante, $P(\text{missing})$, es la misma para todas las instancias y no depende de las medidas de la variable de interés que estemos estudiando u otras variables. ¿Qué quiere decir esto? Si pensamos en una encuesta, corresponde a que el/la encuestador/a se olvide de hacer una pregunta, o pierda hojas con respuestas, es decir, algo que sucede completamente por azar. En general, esta situación es muy poco frecuente.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing At Random (MAR):** $P(missing)$ no depende del valor faltante, pero sí de otras variables observables. Por ejemplo, la pregunta “¿Cuánto gana?” en una encuesta tal vez no es respondida porque el/la encuestado/a considera la pregunta inapropiada, independientemente del monto que perciba.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing At Random (MAR):** $P(\text{missing})$ no depende del valor faltante, pero sí de otras variables observables. Por ejemplo, la pregunta "¿Cuánto gana?" en una encuesta tal vez no es respondida porque el/la encuestado/a considera la pregunta inapropiada, independientemente del monto que perciba.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing Not At Random (MNAR):** en este caso, $P(\text{missing})$ depende de la variable que queremos medir. Por ejemplo, la pregunta “¿Cuánto gana?” en una encuesta tal vez no es respondida porque el/la encuestado/a no quiere revelar su sueldo, ya sea porque lo considera muy bajo o muy alto.

Valores Faltantes

Nombre	Edad (2023)	Profesión	Estatura	¿Sabe Python?	Vive
Emanuel Ginóbili	46	Basquetbolista	Alto	No	Sí
Ada Lovelace	NaN	Programadora	NaN	NaN	No
Mirtha Legrand	NaN	Conductora	Regular	NaN	Sí
Chuck Norris	83	Todas	Regular	Sí	Sí
Guido van Rossum	67	Programador	NaN	Sí	Sí

- **Missing Not At Random (MNAR):** en este caso, $P(\text{missing})$ depende de la variable que queremos medir. Por ejemplo, la pregunta “¿Cuánto gana?” en una encuesta tal vez no es respondida porque el/la encuestado/a no quiere revelar su sueldo, ya sea porque lo considera muy bajo o muy alto.

Valores Faltantes

¿Qué hacemos con los valores faltantes?

- **Eliminar los datos con problemas.** Es una estrategia sencilla y, a veces, efectiva. Se puede hacer de dos formas:
 - Eliminamos las instancias (*por fila*) que tienen algún valor faltante.
 - Eliminamos aquella variable/atributo (por columna) que tiene muchos valores faltantes.
- **Imputación.** Rellenar los valores faltantes con estadísticos obtenidos de los datos que sí tenemos.
 - Promedio/mediana/moda de ese atributo.
 - Agrupamos por alguna categoría relevante e imputamos por promedios en esa categoría.
 - Imputamos por el Vecino Más cercano
 - Entrenamos un modelo.
- **Agregar una variable dummy** por atributo que indique si hay un valor faltante o no, por más que el valor faltante haya sido imputado. De esta forma, le podemos “decir” al modelo que ese valor es un valor faltante.

Valores Faltantes

¿Qué hacemos con los valores faltantes?

- **Imputación.** Rellenar los valores faltantes con estadísticos obtenidos de los datos que sí tenemos.
 - Promedio/mediana/moda de ese atributo.
 - Agrupamos por alguna categoría relevante e imputamos por promedios en esa categoría.
 - Imputamos por el Vecino Más cercano
 - Entrenamos un modelo.

Table 1.1: Overview of assumptions made by ad-hoc methods.

	Unbiased			Standard Error
	Mean	Reg Weight	Correlation	
Listwise	MCAR	MCAR	MCAR	Too large
Pairwise	MCAR	MCAR	MCAR	Complicated
Mean	MCAR	–	–	Too small
Regression	MAR	MAR	–	Too small
Stochastic	MAR	MAR	MAR	Too small
LOCF	–	–	–	Too small
Indicator	–	–	–	Too small

Table 1.1 provides a summary of the methods discussed in this section. The table addresses two topics: whether the method yields the correct results on average (unbiasedness), and whether it produces the correct standard error. Unbiasedness is evaluated with respect to three types of estimates: the mean, the regression weight (with the incomplete variable as dependent) and the correlation.

<https://stefvanbuuren.name/fimd/sec-simplesolutions.html>