
Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín

Repaso

Tipos de problemas que resuelve el Aprendizaje Supervisado

Problemas de clasificación

Necesitan predecir **la clase más probable de un elemento**, en función de un conjunto de variables de entrada. Para este tipo de algoritmos, la variable target o respuesta, **es una variable de tipo categórica**.

Problemas de regresión

En vez de predecir categorías, **predicen valores numéricos**. Es decir, la variable target en un problema de regresión **es de tipo cuantitativa**.

Regresión

¿Qué podemos hacer para diferenciarlos?



IAA_Clase_4_Demo_Regresión.ipynb

Regresión

Consiste en predecir una respuesta numérica y en base a p atributos $x_1, x_2, \dots, x_p$.


$$y \approx f(x_1, x_2, \dots, x_p)$$

Regresión

Consiste en predecir una respuesta numérica y en base a p atributos $x_1, x_2, \dots, x_p$.

$$y \approx f(x_1, x_2, \dots, x_p)$$

El caso más sencillo
es una **regresión
lineal**.



Regresión Lineal Simple

Asumimos que entre y y la - por ahora - única variable predictora x hay una relación lineal:

$$y = \beta_0 + \beta_1 x$$

donde β_0 es la ordenada al origen y β_1 es la pendiente. Es la famosa ecuación de la recta.

Más en general, β_i , $i=0,1$, son los *coeficientes* o, en algunos ámbitos, *pesos*.

Regresión Lineal Simple

Asumimos que entre y y la - por ahora - única variable predictora x hay una relación lineal:

$$y = \beta_0 + \beta_1 x$$

donde β_0 es la ordenada al origen y β_1 es la pendiente. Es la famosa ecuación de la recta.

Más en general, β_i , $i=0,1$, son los *coeficientes* o, en algunos ámbitos, *pesos*.

“Entrenar” un modelo consiste en obtener β_0 y β_1 (en otros ámbitos se suele decir “ajustar”).

Regresión Lineal Simple

Asumimos que entre y y la - por ahora - única variable predictora x hay una relación lineal:

$$y = \beta_0 + \beta_1 x$$


donde β_0 es la ordenada al origen y β_1 es la pendiente. Es la famosa ecuación de la recta.

Más en general, β_i , $i=0,1$, son los *coeficientes* o, en algunos ámbitos, *pesos*.


“Entrenar” un modelo consiste en obtener β_0 y β_1 (en otros ámbitos se suele decir “ajustar”).

¿Cómo obtenemos los coeficientes?

Estimando los coeficientes




Estimando los coeficientes



Estimando los coeficientes

- Llamamos $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ la predicción para la instancia i -ésima. Entonces, el residuo o error de predicción es:

$$e_i = y_i - \hat{y}_i$$



target valor predicho

Estimando los coeficientes

- Llamamos $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ la predicción para la instancia i -ésima. Entonces, el residuo o error de predicción es:

$$e_i = y_i - \hat{y}_i$$

target valor predicho




Estimando los coeficientes

- Llamamos $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ la predicción para la instancia i -ésima. Entonces, el residuo o error de predicción es:

$$e_i = y_i - \hat{y}_i$$

target valor predicho



- La suma de residuos cuadráticos (RSS, *residual sum of squares*) es la suma del cuadrado de los residuos sobre las n instancias del conjunto de datos:

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$


RSS es, efectivamente, una métrica que compara las predicciones y los targets.

Estimando los coeficientes

- Llamamos $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ la predicción para la instancia i -ésima. Entonces, el residuo o error de predicción es:

$$e_i = y_i - \hat{y}_i$$

target valor predicho



- La suma de residuos cuadráticos (RSS, *residual sum of squares*) es la suma del cuadrado de los residuos sobre las n instancias del conjunto de datos:

$$\text{RSS} = e_1^2 + e_2^2 + \dots + e_n^2$$

RSS es, efectivamente, una métrica que compara las predicciones y los targets.

¿De qué depende el RSS?

Estimando los coeficientes

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$

Estimando los coeficientes

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$



$$e_i = y_i - \hat{y}_i \quad \text{donde} \quad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Estimando los coeficientes

$$\text{RSS} = e_1^2 + e_2^2 + \cdots + e_n^2$$



$$e_i = y_i - \hat{y}_i \quad \text{donde} \quad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿De qué depende el RSS?

Dado un conjunto de datos - pares de (x_i, y_i) - el **RSS depende (es función de) de β_0 y β_1**

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1**

Es un ejercicio de análisis II. Derivo con respecto β_0 y β_1 y buscamos dónde las derivadas se hacen 0. Se conoce como **método de cuadrados mínimos**.

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1**

Es un ejercicio de análisis II. Derivo con respecto β_0 y β_1 y buscamos dónde las derivadas se hacen 0. Se conoce como **método de cuadrados mínimos**.

$$\frac{\delta \text{RSS}}{\delta \hat{\beta}_0} = 0$$

$$\frac{\delta \text{RSS}}{\delta \hat{\beta}_1} = 0$$

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1**

Es un ejercicio de análisis II. Derivo con respecto β_0 y β_1 y buscamos dónde las derivadas se hacen 0. Se conoce como **método de cuadrados mínimos**.

$$\frac{\delta \text{RSS}}{\delta \hat{\beta}_0} = 0$$

$$\frac{\delta \text{RSS}}{\delta \hat{\beta}_1} = 0$$

cuya solución es:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$

donde $\bar{x}$ e $\bar{y}$ son el promedio de los x_i e y_i , respectivamente.

Estimando los coeficientes

Enfoque estadístico (Como en SciPy y otros)

Bajo ciertas hipótesis, se puede calcular el *error estándar* de los coeficientes:

$$\text{SE}(\hat{\beta}_0)^2 = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right], \quad \text{SE}(\hat{\beta}_1)^2 = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

donde

$$\sigma^2 = \text{Var}(\epsilon)$$

Y, a partir de ellos, intervalos de confianza. Por ejemplo, hay aproximadamente un 95% de probabilidad que el verdadero valor de β_1 (el valor poblacional), esté en el intervalo

$$\left[\hat{\beta}_1 - 2 \cdot \text{SE}(\hat{\beta}_1), \hat{\beta}_1 + 2 \cdot \text{SE}(\hat{\beta}_1) \right]$$

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1**

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1 (Cuadrados mínimos)**
 - Existen otros métodos similares que dan respuestas “exactas” (máxima verosimilitud, etc.).

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1 (Cuadrados mínimos)**
 - Existen otros métodos similares que dan respuestas “exactas” (máxima verosimilitud, etc.).
- Método(s) 2: **Métodos computacionales.**
 - Búsqueda por grilla: calculo el costo (RSS) para combinaciones de β_0 y β_1 y selecciono la combinación de menor costo.
 - **Mejor:** hago una búsqueda guiada dentro del espacio de parámetros:

Estimando los coeficientes

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

¿Cómo estimamos los coeficientes?

- Método 1: **Minimizando el RSS con respecto a β_0 y β_1 (Cuadrados mínimos)**
 - Existen otros métodos similares que dan respuestas “exactas” (máxima verosimilitud, etc.).
- Método(s) 2: **Métodos computacionales.**
 - Búsqueda por grilla: calculo el costo (RSS) para combinaciones de β_0 y β_1 y selecciono la combinación de menor costo.
 - **Mejor:** hago una búsqueda guiada dentro del espacio de parámetros:

Descenso por gradiente


Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:



Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto. Técnicamente, derivamos o calculamos el gradiente.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto. Técnicamente, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto.
Técnicamente, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto. **Técnicamente**, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto. **Técnicamente**, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto.
Técnicamente, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:




Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto.
Técnicamente, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Descenso por gradiente

Queremos obtener el mínimo, pero no hicimos una exploración exhaustiva de la función de costo:



Pasos

1. Calculamos el costo para ciertos valores al azar de los parámetros.
2. Repetimos hasta converger
 - a. Nos fijamos la dirección de decrecimiento en ese punto. **Técnicamente**, derivamos o calculamos el gradiente.
 - b. Actualizamos los valores de los parámetros.

Regresión Lineal Múltiple

Regresión Lineal Múltiple

En lugar de un atributo predictor, tenemos p atributos predictores

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$



Regresión Lineal Múltiple

En lugar de un atributo predictor, tenemos p atributos predictores

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$

El caso con dos atributos, x_1 y x_2 , todavía lo podemos visualizar:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$



Regresión Lineal Múltiple - Estimando los coeficientes

- Los métodos vistos para la Regresión Lineal Simple siguen valiendo.
 - Aunque en dimensiones muy altas (muchos predictores) se suelen preferir los métodos computacionales.

Regresión Lineal Múltiple - Estimando los coeficientes

- Los métodos vistos para la Regresión Lineal Simple siguen valiendo.
 - Aunque en dimensiones muy altas (muchos predictores) se suelen preferir los métodos computacionales.
- Muchas veces se suele recurrir a notación matricial:

$$y = \mathbf{X}\beta$$

donde

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

Ordenada al origen

Pendiente de cada
atributo

Regresión Lineal Múltiple - Estimando los coeficientes

- Los métodos vistos para la Regresión Lineal Simple siguen valiendo.
 - Aunque en dimensiones muy altas (muchos predictores) se suelen preferir los métodos computacionales.
- Muchas veces se suele recurrir a notación matricial:

$$y = \mathbf{X}\beta$$

donde

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

Ordenada al origen

Pendiente de cada atributo

- Y la solución de cuadrados mínimos es:

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y$$

Evaluación: métricas

Métricas

- Error cuadrático medio (MSE según sus siglas en inglés):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Métricas

- Error cuadrático medio (MSE según sus siglas en inglés):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{MSE}$$

Métricas

- Error cuadrático medio (MSE según sus siglas en inglés):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Raíz del error cuadrático medio:

$$RMSE = \sqrt{MSE}$$

- Error absoluto medio:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Métricas

- Coeficiente de determinación:

$$R^2 = \frac{\text{TSS} - \text{RSS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$$

Métricas

- Coeficiente de determinación:

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

donde

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Métricas

- Coeficiente de determinación:

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

donde

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

**Variabilidad total de los
datos**

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

**Variabilidad no explicada
por el modelo**

Métricas

- Coeficiente de determinación:

$$R^2 = \frac{TSS - RSS}{TSS} = 1 - \frac{RSS}{TSS}$$

donde

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

**Variabilidad total de los
datos**

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

**Variabilidad no explicada
por el modelo**

$R^2 \rightarrow 0$ cuando el modelo explica poco de la variabilidad de los datos

$R^2 \rightarrow 1$ cuando el modelo explica mucha de la variabilidad de los datos

En casos atípicos, puede ser negativa.

Otros modelos



Árboles de decisión para regresión

Construcción

En cada nodo, usar reducción de desvío estándar de Y en lugar de gini/info gain.

Consulta

Al llegar a una hoja, devolver el promedio de Y sobre las instancias de la hoja.



Bibliografía

- *An Introduction to Statistical Learning*. Capítulos 3 y 8 (comienzo).
- *The Data Science Design Manual*, de Steven S. Skiena. Capítulo 9.