
Introducción al Aprendizaje Automático

1er cuatrimestre 2025




Universidad
Nacional
de San Martín



Regresión Logística

Modelo de Regresión Logística


Motivación





Motivación





Motivación





- ¿No son raros los cambios abruptos de una hoja a otra?
- ¿No andaría mejor una frontera lineal?



¿Cómo sería?



¿Cómo sería?




Existe varias formas de elegir la “mejor” recta.

La que vamos a ver hoy se basa en la función sigmoide.

Función sigmoide

$$\sigma(z) = \frac{1}{1+e^{-z}}$$




Función sigmoide

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

¿Quién es “z”?

¿Por qué sirve para clasificar?

¿Por qué genera fronteras lineales?



Regresión Logística

- Z va a ser una función de los atributos.
- La forma más fácil: **una lineal**
 - Un atributo: $w_1x_1 + w_0$

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

$$f(x_1) = \frac{1}{1 + e^{-(w_1x_1+w_0)}}$$

Regresión Logística

- Z va a ser una función de los atributos.
- La forma más fácil: **una lineal**

$$\sigma(z) = \frac{1}{1+e^{-z}}$$

- Un atributo: $w_1x_1 + w_0$

$$f(x_1) = \frac{1}{1 + e^{-(w_1x_1 + w_0)}}$$

- Dos atributos: $w_1x_1 + w_2x_2 + w_0$


$$f(x_1, x_2) = \frac{1}{1 + e^{-(w_1x_1 + w_2x_2 + w_0)}}$$

$w_{i,i>0}$: pesos (*weights*), w_0 : bias



Regresión Logística

Un atributo




Un atributo



Un atributo



Un atributo



Frontera de decisión

¿Cómo se obtiene una frontera? ¡Hay que elegir un umbral para la probabilidad!
Típicamente, 0.5.

- Un atributo

$$p(x_u) = 0.5$$




$$\frac{1}{1+e^{-(w_0+w_1x_u)}} = 0.5$$

$$e^{-(w_0+w_1x_u)} = 1$$





$$w_0 + w_1x_u = 0$$

$$x_u = -\frac{w_0}{w_1}$$






Un atributo



Frontera de decisión



Frontera de decisión



Regresión Logística

¿Por qué tiene sentido?

Modelos Discriminativos

Un modelo discriminativo es un modelo de la probabilidad condicional $P(Y|X)$, es decir, la probabilidad de observar el target Y dadas las observaciones X.

En el caso binario, basta modelar la probabilidad de una de las clases. Por ejemplo,

$$P(Y = C_1|X = x)$$

se lee como la probabilidad que una instancia con atributos x pertenezca a la clase C_1 .

En general, resumimos en $P(Y = C_1|X = x) = P(C_1)$, pero no hay que olvidar que **la probabilidad dependerá de los atributos X**.

*Un poco de abuso de notación.


Probabilidad

En el caso binario, si la clase A tiene p probabilidad, la clase B tiene probabilidad $1 - p$. La razón entre esas dos probabilidad se conoce como *odds*¹:

$$odds = p / (1 - p)$$

Algunos ejemplos:

- $p = 0.5 \rightarrow odds = 0.5/0.5 \rightarrow 1$
- $p = 0.75 \rightarrow odds = 0.75/0.25 \rightarrow 3$
- $p = 0.9 \rightarrow odds = 0.9/0.1 \rightarrow 9$
- $p = 0.99 \rightarrow odds = 0.99/0.01 \rightarrow 99$




¹**Cuota** o el **momio** en castellano, pero muy poco usado.

Probabilidad

Al logaritmo de *odds* magnitud se lo conoce como *log odds* o **logit**:

$$\text{logit}(p) = \ln\left(\frac{p}{1-p}\right)$$



Probabilidad

¿De qué depende la probabilidad? ¡De los atributos!

$$p(x) = w_0 + w_1 x$$

Probabilidad

¿De qué depende la probabilidad? ¡De los atributos!

$$p(x) = w_0 + w_1 x$$



Probabilidad

¿De qué depende la probabilidad? ¡De los atributos!

$$p(x) = w_0 + w_1 x$$



$$\text{logit}(p(x)) = w_0 + w_1 x$$



A la función $f(t) = 1 / (1 + e^{-t})$ se la conoce como **función logística**. A este modelo de la probabilidad se lo conoce como **Regresión Logística**.

Probabilidad

¿De qué depende la probabilidad? ¡De los atributos!

$$p(x) = w_0 + w_1 x$$



$$\text{logit}(p(x)) = w_0 + w_1 x$$



$$\ln\left(\frac{p(x)}{1-p(x)}\right) = w_0 + w_1 x$$

$$\frac{p(x)}{1-p(x)} = e^{w_0 + w_1 x}$$


$$p(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$

A la función $f(t) = 1 / (1 + e^{-t})$ se la conoce como **función logística**. A este modelo de la probabilidad se lo conoce como **Regresión Logística**.


Regresión Logística

¿Cómo se obtienen los pesos?


Aprendizaje Supervisado




Aprendizaje Supervisado




	feature 1	feature 2	...	feature M	target
muestra 1	"Matriz de diseño"				
muestra 2					
muestra 3					
...					
muestra N					




Aprendizaje Supervisado



Aprendizaje Supervisado



Aprendizaje Supervisado



¿Y cómo se obtienen los pesos w_i ?

Recordamos que la [optimización](#) es la selección del mejor elemento (con respecto a algún criterio)

Problemas de optimización [\[editar \]](#)

Un problema de optimización puede ser representado de la siguiente forma:

Dada: una [función](#) $f: A \rightarrow R$.

Buscar: un elemento x_0 en A tal que $f(x_0) \leq f(x)$ para todo x en A («minimización») o tal que $f(x_0) \geq f(x)$ para todo x en A («maximización»).

Tal formulación es llamada un problema de optimización o un problema de programación matemática (un

Cuando la función objetivo es convexa, entonces cualquier mínimo local será también un mínimo global.

[lista](#) de técnicas de optimización computacional: algoritmos, métodos iterativos, heurísticos, etc.

¿Y cómo se obtienen los pesos w_i ?

Los pesos se obtienen optimizando una función de costo. ¿Cuál usamos en este caso?

En PyE una función muy utilizada es la *verosimilitud*.

$$L(w_0, w_1, \dots, w_n) = \prod_{i:y_i=1} p(x_i) \prod_{i':y_{i'}=0} (1 - p(x_{i'}))$$

$$L^*(w_0, w_1, \dots, w_n) = \sum_{i:y_i=1} \log(p(x_i)) + \sum_{i':y_{i'}=0} \log(1 - p(x_{i'}))$$

$$L^*(w_0, w_1, \dots, w_n) = \sum_i (y_i \log(p(x_i)) + (1 - y_i) \log(1 - p(x_i)))$$

Buscamos maximizar la verosimilitud, lo que es equivalente a minimizar $-L^*$ (también conocido como entropía cruzada).

Un método utilizado para encontrar el extremo se conoce como *descenso por gradiente*.

El código

SciKit-Learn ofrece la clase [LogisticRegression\(\)](#) que implementa un modelo lineal para clasificación (multiclase).

Diferentes [solvers](#) permiten optar el algoritmo de optimización según el problema (*tamaño del conjunto de datos, cantidad de atributos, multiclase, etc.*)



The screenshot shows the SciKit-Learn API Reference page for the `LogisticRegression` class. The page has a dark theme. At the top, there is a navigation bar with the SciKit-Learn logo on the left and search and menu icons on the right. Below the navigation bar, the breadcrumb trail reads: `API Reference > sklearn.linear_model > LogisticRegression`. The main heading is `LogisticRegression`. Below the heading, the class signature is displayed in a code block: `class sklearn.linear_model.LogisticRegression(penalty='l2', *, dual=False, tol=0.0001, C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, random_state=None, solver='lbfgs', max_iter=100, multi_class='deprecated', verbose=0, warm_start=False, n_jobs=None, l1_ratio=None)`. A [\[source\]](#) link is located at the bottom right of the code block.

```
class sklearn.linear_model.LogisticRegression(penalty='l2', *, dual=False, tol=0.0001,
C=1.0, fit_intercept=True, intercept_scaling=1, class_weight=None, random_state=None,
solver='lbfgs', max_iter=100, multi_class='deprecated', verbose=0, warm_start=False,
n_jobs=None, l1_ratio=None)
```

[\[source\]](#)

¿Y cómo se obtienen los pesos w_i ?

