
Introducción al Aprendizaje Automático

1er cuatrimestre 2025



Universidad
Nacional
de San Martín


Repaso

Regresión

Consiste en predecir una respuesta numérica y en base a p atributos $x_1, x_2, \dots, x_p$.

$$y \approx f(x_1, x_2, \dots, x_p)$$

El caso más sencillo
es una **regresión
lineal**.





Regresión Lineal Múltiple

En lugar de un atributo predictor, tenemos p atributos predictores

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$

El caso con dos atributos, x_1 y x_2 , todavía lo podemos visualizar:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$



Regresión Lineal Múltiple

- En notación matricial:

$$y = \mathbf{X}\beta$$

donde

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

Ordenada al origen

Pendiente de cada atributo

- Y la solución de cuadrados mínimos es:

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y$$

Regresión Lineal Múltiple

- En notación matricial:

$$y = \mathbf{X}\beta$$

donde

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{pmatrix}$$

$$\beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}$$

Ordenada al origen

Pendiente de cada atributo

- Y la solución de cuadrados mínimos es:

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T y$$



Regresión Lineal Múltiple

En lugar de un atributo predictor, tenemos p atributos predictores

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \cdots + \hat{\beta}_p x_p$$

El caso con dos atributos, x_1 y x_2 , todavía lo podemos visualizar:


$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$



Función de costo

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

$$\text{MSE}(\vec{y}; \vec{t}) = \frac{1}{M} \sum_{i=1}^M (y^{(i)} - t^{(i)})^2$$




Función de costo

$$\text{RSS} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \cdots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

$$\text{MSE}(\vec{y}; \vec{t}) = \frac{1}{M} \sum_{i=1}^M (y^{(i)} - t^{(i)})^2$$

En general, la función de costo (o pérdida) es aquella que se minimiza durante el entrenamiento, dando como resultado los parámetros del modelo


$$L(\vec{w}; \vec{x}, \vec{t})$$



Regresión polinomial

Modelos polinomiales

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_n x_n$$




Modelos polinomiales

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_n x_n$$

Todo lo que vimos hasta ahora es independiente de quienes sean las variables.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$




Modelos polinomiales

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_n x_n$$

Todo lo que vimos hasta ahora es independiente de quienes sean las variables.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$$




Modelos polinomiales

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_n x_n$$

Todo lo que vimos hasta ahora es independiente de quienes sean las variables.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \hat{\beta}_3 x^3$$




Modelos polinomiales

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_n x_n$$







Todo lo que vimos hasta ahora es independiente de quienes sean las variables.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \hat{\beta}_3 x^3$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2 + \dots + \hat{\beta}_n x^n$$



Modelos polinomiales



Regularización

Flexibilidad de un Modelo

¿Cómo medimos la flexibilidad de un modelo?

- Número de parámetros.

¿Cómo limitamos la flexibilidad de un modelo?

- Menor $M \rightarrow$ Menor número de parámetros.





Figure 1.4 Plots of polynomials having various orders M , shown as red curves, fitted to the data set shown in Figure 1.2.

Flexibilidad de un Modelo



- Parametros grandes $\rightarrow$ gran sensibilidad ante variaciones de las variables $\rightarrow$ mayor varianza

Flexibilidad de un Modelo

¿Cómo medimos la flexibilidad de un modelo?

- Número de parámetros.

¿Cómo limitamos la flexibilidad de un modelo?

- Menor $M \rightarrow$ Menor número de parámetros.
- **Tamaño de los parámetros.**




Figure 1.4 Plots of polynomials having various orders M , shown as red curves, fitted to the data set shown in Figure 1.2.

Regularización

“Mantengamos los pesos pequeños”

¿Cómo se eligen los pesos?

- Función de pérdida

$$L(y, t) = (y - t)^2$$

$$L(y; t) = -[t \log(y)(1 - t) \log(1 - y)]$$

¿Cómo puedo hacer para *forzarlos* a ser pequeños?

- Añadir un término que **penalice** su tamaño.

$$L(\vec{w}; \vec{x}, \vec{t}) \rightarrow L(\vec{w}; \vec{x}, \vec{t}) + \lambda L_{reg}(\vec{w})$$

Término de **regularización**
ó penalización

Coeficiente de **regularización**

Regularización

“Mantengamos los pesos pequeños”

¿Cómo se eligen los pesos?

- Función de pérdida

$$L(y, t) = (y - t)^2$$
$$L(y; t) = -[t \log(y)(1 - t) \log(1 - y)]$$

¿Cómo puedo hacer para *forzarlos* a ser pequeños?

- Añadir un término que **penalice** su tamaño.

$$L(\vec{w}; \vec{x}, \vec{t}) \rightarrow L(\vec{w}; \vec{x}, \vec{t}) + \lambda L_{reg}(\vec{w})$$

Término de **regularización**
ó penalización

Coefficiente de **regularización**

Hiperparámetro!

Regularización

“Mantengamos los pesos pequeños”

Ridge o L2

- Módulo cuadrado de los coeficientes

$$L_{reg}(\vec{w}) = \|\vec{w}\|_2^2 = \sum_{i=1}^M |w_i|^2$$

Lasso o L1

- Módulo de los coeficientes

$$L_{reg}(\vec{w}) = \|\vec{w}\|_1 = \sum_{i=1}^M |w_i|$$

Regularización

“Mantengamos los pesos pequeños”

Ridge o L2

- Módulo cuadrado de los coeficientes

$$L_{reg}(\vec{w}) = \|\vec{w}\|_2^2 = \sum_{i=1}^M |w_i|^2$$

Lasso o L1

- Módulo de los coeficientes

$$L_{reg}(\vec{w}) = \|\vec{w}\|_1 = \sum_{i=1}^M |w_i|$$


En descenso por gradiente,
vamos ajustando los pesos según
la derivada de la función de costo

$$\omega_i \rightarrow \omega_i - \alpha \frac{\partial L}{\partial \omega_i}$$
$$\frac{\partial L_{Ridge}}{\partial \omega_i} \rightarrow \omega_i$$
$$\frac{\partial L_{Lasso}}{\partial \omega_i} \rightarrow 1$$


Regularización

“Mantengamos los pesos pequeños”

Lasso - L1




Ridge - L2



Regularización

"Mantengamos los pesos pequeños"

Lasso - L1



Ridge - L2

